

UNL - FICH - Ingeniería en Inteligencia Artificial

Laboratorio de Datos II

Guía de ejercicios N° 1

Análisis Exploratorio de Datos y Visualización

El Análisis Exploratorio de Datos (EDA) constituye una etapa fundamental en cualquier proyecto de Inteligencia Artificial, permitiendo comprender la estructura, patrones y características de los datos antes de aplicar técnicas de modelado. A través del EDA, es posible identificar tendencias, detectar anomalías, evaluar la calidad de los datos y generar hipótesis que guíen el desarrollo posterior del proyecto.

La visualización de datos, por su parte, representa una herramienta esencial para la comunicación efectiva de hallazgos, transformando información compleja en representaciones gráficas comprensibles que faciliten la toma de decisiones basada en evidencias.

En esta guía trabajaremos con el dataset Palmer Penguins¹, que contiene información sobre tres especies de pingüinos (Adelie, Chinstrap y Gentoo) recolectada en islas del archipiélago Palmer (Antártida).

Ejercicio 1: Estadística Descriptiva y Análisis Univariado

Realice un análisis estadístico descriptivo completo de la base de datos.

Tareas a realizar:

- Cargue el dataset y examine su estructura básica (dimensiones, tipos de datos, valores faltantes). Para la carga de la base de datos, utilice el comando:

```
datos_penguins = sns.load_dataset('penguins')
```

Considere los comandos `shape`, `info` y `isnull().sum()` de la librería `pandas` para explorar la estructura y los valores faltantes.

- Calcule las estadísticas descriptivas fundamentales (media, mediana, moda, desviación estándar, cuartiles) para las variables numéricas. Considere los comandos `describe`, `median` y `mode` de `pandas` para obtener estos valores de forma directa.

¹ <https://github.com/allisonhorst/penguins>

- Calcule estadísticas de orden superior (asimetría y curtosis) e interprete su significado en el contexto del problema. Considere los comandos `skew` y `kurtosis` del módulo `stats` de la librería `scipy`, aplicados a las series numéricas.
- Genere histogramas para las variables numéricas, evaluando la forma de sus distribuciones. Considere los comandos `hist` de `pandas` y `matplotlib`, así como `histplot` del módulo `seaborn`.
- Construya boxplots para identificar valores atípicos en las variables numéricas. Considere el comando `boxplot` de `matplotlib` o `seaborn`.
- Identifique la distribución de las variables categóricas mediante tablas de frecuencia. Considere el comando `value_counts` de `pandas` para obtener la frecuencia absoluta de cada categoría.

Genere un reporte descriptivo que caracterice completamente la distribución univariada de cada variable, identificando patrones, anomalías y características relevantes para análisis posteriores.

Ejercicio 2: Análisis Bivariado - Correlaciones y Asociaciones

Explore las relaciones entre pares de variables utilizando técnicas de análisis bivariado.

Tareas a realizar:

- Calcule la matriz de correlación para todas las variables numéricas y visualícela mediante un heatmap. Considere el comando `corr` de `pandas` para calcular la matriz. Para la visualización, utilice `heatmap` de `seaborn` o `DataFrame.plot.imshow` de `pandas`.
- Genere scatter plots para las relaciones más significativas, incorporando líneas de tendencia. Considere el comando `scatterplot` de `seaborn` o `matplotlib.pyplot.scatter` para graficar puntos. Para incluir líneas de tendencia, utilice `lmplot` de `seaborn`.
- Identifique correlaciones espurias y evalúe la significancia estadística de las asociaciones encontradas. Considere el comando `corr` de `pandas` o `corrcoef` de `numpy` para calcular coeficientes, y utilice las funciones `pearsonr` o `spearmanr` del módulo `stats` de `scipy` para obtener el valor del coeficiente y su significancia (valor p).
- Analice la relación entre "bill_length_mm" y "bill_depth_mm" segmentada por especie utilizando gráficos de dispersión con codificación por color. Considere el comando `scatterplot` de `seaborn`. Si se desea añadir una línea de tendencia, puede emplear `lmplot` de `seaborn`.

- Construya tablas de contingencia para examinar la asociación entre variables categóricas. Considere el comando `crosstab` de pandas para generar tablas de doble entrada entre variables categóricas.
- Aplique pruebas de independencia chi-cuadrado para variables categóricas. Considere el comando `chi2_contingency` del módulo `stats` de `scipy`, aplicado a las tablas generadas con `crosstab` de pandas o `contingency.crosstab` de `scipy.stats`.

Genere un reporte que incluya una caracterización completa de las relaciones bivariadas que permita identificar variables predictoras potenciales y patrones de dependencia entre características de las propiedades.

Ejercicio 3: Análisis Multivariado y Visualización Avanzada

Implemente técnicas de análisis multivariado para explorar relaciones complejas entre múltiples variables simultáneamente.

Tareas a realizar:

- Construya una matriz de dispersión (scatter plot matrix) para visualizar todas las relaciones por pares entre variables numéricas. Considere `pairplot` de seaborn o `scatter_matrix` de pandas.plotting.
- Implemente un gráfico de coordenadas paralelas para identificar patrones en las variables morfológicas de las diferentes especies. Considere `parallel_coordinates` de pandas.plotting o `matplotlib.pyplot.plot` con datos normalizados.
- Genere heatmaps de correlación segmentados por especie de pingüino. Considere `corr` de pandas junto con `heatmap` de seaborn, filtrando por especie.
- Aplique técnicas de agrupamiento de variables basadas en correlación para identificar grupos de características morfológicas relacionadas. Considere `corr` de pandas junto con `linkage` y `dendrogram` de `scipy.cluster.hierarchy`.
- Construya gráficos de radar (spider plots) para comparar variables morfológicas promedio entre especies. Considere `matplotlib.pyplot.plot` en coordenadas polares (`subplot(projection='polar')`).

Genere un reporte analizando la estructura multivariada de los datos, e identifique patrones morfológicos asociados con la especie que permita identificar características discriminantes.

Ejercicio 4: Muestreo y Reducción Dimensional

Implemente estrategias de muestreo inteligente y técnicas de reducción dimensional para el manejo eficiente de datos.

Tareas a realizar:

- Implemente diferentes estrategias de muestreo: aleatorio simple y estratificado por especie, comparando la representatividad de cada método. Utilice gráficos adecuados para reflejar la composición de los datos. Considere el método `.sample` de `pandas.DataFrame` para muestreo aleatorio, el método `.groupby` y `.sample` para muestreo estratificado balanceado y `train_test_split` de `sklearn.model_selection` con el parámetro `stratify` para muestreo estratificado manteniendo las proporciones originales de las especies.
- Aplique Análisis de Componentes Principales (PCA) para reducir la dimensionalidad del dataset manteniendo al menos 95% de la varianza explicada. Recordar que se debe normalizar previamente las variables. Se propone el uso de `StandardScaler` de `sklearn.preprocessing` y PCA de `sklearn.decomposition`.
- Visualice los datos originales (`pairplot`) y transformados mediante PCA (2 dimensiones), interpretando los componentes principales obtenidos. La reducción a dos componentes puede realizarse con `PCA(n_components=2)`.
- Evalúe la pérdida de información asociada con diferentes niveles de reducción dimensional. Se recomienda representar gráficamente la varianza acumulada retenida con `explained_variance_ratio_`.
- Aplique una técnica de reducción dimensional no lineal, como t-SNE, y compare la representación obtenida con la proyección mediante PCA en dos dimensiones. Analice visualmente la separación entre especies y discuta las principales diferencias entre ambas representaciones. Considere el uso de TSNE de `sklearn.manifold`.

Determine cuál es la estrategia más adecuada para el manejo de datos que preserve de mejor manera la información esencial, mejorando la eficiencia computacional y la interpretabilidad visual.

Ejercicio 5: Diseño Visual y Narrativa de Datos

El conjunto de datos “Penguins” presenta características típicas del Análisis Exploratorio de Datos (EDA), como valores faltantes, presencia de outliers y alta separabilidad de clases para la tarea de clasificación de especies.

A partir de los contenidos de la unidad, elabore un dashboard interactivo, empleando la librería `Streamlit` de Python, que permita comprobar visualmente estas afirmaciones. El panel deberá:

- Incluir cuatro visualizaciones que evidencien patrones, tendencias, anomalías y la facilidad de separación entre especies.
- Disponer las visualizaciones en una grilla de 2×2 , cuidando la claridad y coherencia visual.
- Seleccionar los tipos de gráficos conforme a los principios de diseño y narrativa con datos estudiados.

Se evaluará la pertinencia de la elección de visualizaciones, la calidad visual y la capacidad del dashboard para comunicar de manera efectiva los hallazgos del análisis.