

Capítulo 1: Introducción al Análisis Exploratorio de Datos (EDA)

Contar historias con datos: el puente entre análisis y comunicación

Basado en Knaflic (2015)

En un mundo saturado de información, generar un gráfico a partir de datos es técnicamente sencillo; sin embargo, crear una visualización que comunique un mensaje de forma clara y efectiva es un desafío mucho mayor. Los “gráficos malos”, como señala Knaflic (2015) en su influyente obra *Storytelling with Data*, están en todas partes. No nacen de una mala intención, sino de una brecha fundamental en nuestra formación: aprendemos a procesar números y a construir frases, pero rara vez se nos enseña a unir ambos mundos para contar historias convincentes con datos.

Knaflic establece una distinción crucial entre dos fases del trabajo con datos: el **análisis exploratorio** y el **análisis explicativo**. El primero, el análisis exploratorio, es el corazón de este capítulo. Ella lo compara con la “búsqueda de perlas en un mar de ostras”. Es el proceso de sumergirse en los datos, examinarlos desde múltiples ángulos, aplicar las técnicas estadísticas y visuales que veremos a continuación para descubrir patrones, identificar anomalías y, en esencia, encontrar esas “perlas” de conocimiento que son significativas. Esta fase es de descubrimiento, caracterizada por la pregunta: *¿qué hay de interesante aquí?*

Por otro lado, el **análisis explicativo** es el acto de presentar esas perlas a una audiencia. En esta etapa, ya no estamos explorando; ya hemos encontrado la historia y nuestro objetivo es comunicarla de la manera más simple y poderosa posible. Significa dejar atrás las cien ostras que abrimos y mostrar únicamente las dos perlas que encontramos. Confundir estas dos fases es un error común: a menudo, los analistas, deseosos de mostrar todo su trabajo, presentan su exploración en lugar de su explicación, abrumando a la audiencia con detalles innecesarios.

Si bien la obra de Knaflic se centra en perfeccionar la fase explicativa, el análisis exploratorio de datos (EDA) es el prerrequisito indispensable. No se puede contar una historia clara si no se ha encontrado primero. Este capítulo se dedica, por tanto, a las herramientas y conceptos fundamentales del EDA: el arte y la ciencia de buscar perlas. A continuación, se resumen las seis lecciones clave que, una vez finalizada la exploración, nos guiarán para comunicar nuestros hallazgos.

El rol del EDA en proyectos de Inteligencia Artificial

Basado en Han, Pei y Tong (2022); McKinney (2022)

El **Análisis Exploratorio de Datos (EDA)** consiste en emplear técnicas estadísticas y visuales para examinar conjuntos de datos con el fin de resumir sus principales características, muchas veces previa a la modelización o al desarrollo de algoritmos de Inteligencia Artificial. Aunque estas tareas iniciales de examinar y limpiar datos puedan parecer **mundanas o triviales**, son en realidad **esenciales en cualquier proyecto de análisis de datos o de IA**. Antes de aplicar algoritmos complejos, el investigador debe entender la estructura y calidad de sus datos, identificar posibles problemas (como valores atípicos, datos faltantes, distribuciones anómalas) y verificar que se cumplan los supuestos estadísticos necesarios.

En proyectos de *Inteligencia Artificial* y *aprendizaje automático*, el EDA juega un papel crítico en varias etapas. Primero, proporciona un **entendimiento básico de los datos y las relaciones entre variables**, lo cual ayuda a guiar la selección o diseño de modelos apropiados y a interpretar correctamente sus resultados. Segundo, permite asegurar que los datos cumplen con los requisitos que exigen las técnicas más avanzadas (por ejemplo, ciertas distribuciones o ausencia de sesgos graves). Ignorar esta fase exploratoria conlleva riesgos: patrones espurios o problemas ocultos en los datos (como outliers no detectados o datos faltantes no tratados) pueden distorsionar drásticamente los resultados de un modelo de IA sin que el analista se percate. Por eso, el EDA suele considerarse una **inversión necesaria** que garantiza la validez de las conclusiones posteriores.

Vale la pena destacar que en la práctica profesional **la mayor parte del tiempo de un proyecto de machine learning se dedica a la preparación y exploración de los datos** (limpieza, ingeniería de características, análisis preliminar) más que al modelado en sí. De hecho, numerosos especialistas concuerdan en que alrededor del **80% del tiempo** en proyectos de *Big Data* o *Data Science* se gasta en **gestión y exploración de datos**, antes de siquiera construir modelos. Esta realidad subraya la importancia del EDA: una comprensión sólida de los datos iniciales sienta las bases para cualquier proyecto exitoso de IA.

Finalmente, el EDA incluye no solo cálculos numéricos sino también **visualizaciones informativas**. El cuarteto de Anscombe de la fig. 1 es el argumento más económico a favor de mirar antes de resumir: cuatro conjuntos con los mismos estadísticos y formas incompatibles entre sí. La generación de gráficos y diagramas es una de las tareas más importantes en análisis de datos, típicamente parte del proceso exploratorio para *identificar outliers*, detectar patrones, o sugerir transformaciones necesarias. Por ejemplo, inspeccionar visualmente distribuciones o relaciones mediante gráficos puede revelar tendencias o anomalías que no serían evidentes solo con tablas de números. En suma, el EDA actúa como puente entre los datos brutos y los modelos predictivos, permitiendo al analista descubrir *a priori* cómo es la estructura de sus datos y qué enfoques pueden funcionar mejor en etapas posteriores de un proyecto de Inteligencia Artificial.




Figura 1: El cuarteto de Anscombe. Los cuatro conjuntos comparten media de x , media de y , varianza y coeficiente de correlación hasta el segundo decimal, y hasta la misma recta de regresión. Un resumen numérico los declara equivalentes.

La vista los separa de inmediato: el primero es una relación lineal con ruido; el segundo, una curva que ninguna recta describe; el tercero, una recta perfecta arruinada por un solo punto atípico; el cuarto, una columna vertical donde una única observación apartada fabrica toda la correlación.

Es el argumento de por qué el análisis exploratorio empieza mirando y no calculando: los estadísticos resumen, y al resumir descartan justamente la forma.

Snippet (Python): checklist EDA inicial

```
1 import pandas as pd
2 import seaborn as sns
3
4 def eda_resumen(df: pd.DataFrame, top_n=5):
5     info = pd.DataFrame({
6         "dtype": df.dtypes,
7         "n_nulos": df.isna().sum(),
8         "pct_nulos": df.isna().mean().round(3),
9         "n_unicos": df.nunique(),
10    })
11    return info.sort_index(), df.head(top_n), df.describe(include="all").T
12
13 pinguinos = sns.load_dataset("penguins")
14 info, cabeza, descriptivos = eda_resumen(pinguinos)
15 print(info)
```

Estadística Descriptiva: Conceptos Básicos y Aplicaciones

Basado en McKinney (2022); Han, Pei y Tong (2022)

La **estadística descriptiva** es el conjunto de técnicas que permiten resumir y presentar la información contenida en un

conjunto de datos, de forma cuantitativa (medidas numéricas) o gráfica, facilitando su comprensión. A diferencia de la estadística inferencial –que busca sacar conclusiones o predicciones acerca de una población más amplia a partir de una muestra– la estadística descriptiva **se limita a describir las propiedades del conjunto de datos disponible**, sin intentar generalizar más allá. Sus medidas y representaciones ayudan a obtener una **primera impresión** de los datos y son frecuentemente el primer paso del EDA en un proyecto de IA.

Entre las **aplicaciones** de la estadística descriptiva se incluye: (a) **resumir distribuciones** de variables mediante pocos números (por ejemplo, promedios, porcentajes, rangos) de modo que sea más fácil comunicar las características principales de los datos; (b) **identificar posibles valores atípicos o errores** en los datos, al detectar valores numéricos inusualmente altos o bajos, o categorías con frecuencias inesperadas; (c) **comparar grupos o relaciones simples** entre dos variables antes de aplicar modelos más complejos; y (d) **preparar la información para análisis posteriores**, por ejemplo, rellenando datos faltantes con medidas descriptivas o normalizando variables de acuerdo a su dispersión.

Un principio fundamental es que, para realizar una buena preparación de datos, **es esencial tener una visión global del conjunto de datos**. Las descripciones estadísticas básicas proporcionan esa visión panorámica, permitiendo **identificar propiedades importantes** de los datos y señalar qué valores podrían ser ruido o outliers que requieran atención. Por ejemplo, conocer elementos como el promedio, la variabilidad y la forma de la distribución de cada atributo facilita tareas de preprocesamiento como la imputación de valores faltantes, la detección de valores extremos o la elección de transformaciones adecuadas. De este modo, la estadística descriptiva se convierte en una herramienta fundamental para “resumir o describir una colección de datos” de forma comprensible, sirviendo de base para técnicas más avanzadas de minería de datos, aprendizaje automático y visualización.

A continuación, revisaremos las técnicas descriptivas más comunes en tres niveles de análisis: **univariado**, **bivariado** y **multivariado**. En cada caso, discutiremos las medidas estadísticas relevantes y las estrategias de visualización apropiadas.

| Snippet (Python): descriptivos rápidos

```
1 import numpy as np
2 import seaborn as sns
3
4 pinguinos = sns.load_dataset("penguins")
5
6 numericas = pinguinos.select_dtypes(include=[np.number])
7 resumen = numericas.agg(["count", "mean", "median", "std", "min", "max"]).T
8 resumen["IQR"] = numericas.quantile(0.75) - numericas.quantile(0.25)
9 print(resumen.round(2))
```

Análisis Univariado: Distribuciones, Medidas Descriptivas y Visualización

Basado en McKinney (2022); Hair et al. (2019)

El **análisis univariado** se enfoca en examinar una variable a la vez, caracterizando su distribución y propiedades fundamentales. El objetivo es entender cómo se distribuyen los valores de esa variable en el conjunto de datos. Para ello, la estadística descriptiva provee varias medidas resumen de dos tipos principales: **tendencia central** y **dispersión** (variabilidad). Adicionalmente, se consideran medidas de forma de la distribución (asimetría y curtosis, a veces llamadas estadísticos de orden superior) y representaciones gráficas que ayudan a apreciar dichas características de un vistazo.

- **Distribución de frecuencias:** Antes de calcular cualquier estadístico, es útil considerar la distribución de valores de la variable. Para variables categóricas, esto implica contar la frecuencia de cada categoría; para variables numéricas, suele implicar agrupar valores en rangos (intervalos) y observar cuántos caen en cada rango. Estas distribuciones pueden visualizarse mediante **gráficos de barras** (categóricas) o **histogramas** (numéricas), dando una primera idea de la forma de la distribución (simétrica o sesgada, unimodal o multimodal, etc.).
- **Medidas de tendencia central:** Indican dónde se “centran” los datos en la escala de valores. La más conocida es la **media aritmética**, que es el promedio de todos los valores. Formalmente, para valores $x_1, x_2, \dots, x_N$, la media es $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$. La media resume en un solo número el valor típico de la variable. Sin embargo, **no siempre es representativa**, especialmente si la distribución es asimétrica o contiene valores atípicos extremos, ya que la media es sensible a esos valores extremos. Por ello se consideran también la **mediana** (valor central que divide a la mitad

los datos ordenados) y la **moda** (el valor más frecuente). La mediana es más robusta frente a outliers: por ejemplo, en una distribución salarial muy sesgada por unos pocos sueldos altísimos, la mediana dará una idea más realista del salario “típico” que la media. Otras veces se cita el **rango medio (midrange)**, calculado como el promedio del valor mínimo y máximo, aunque este es muy sensible a extremos y menos usado. Estas medidas responden a la pregunta: “¿En torno a qué valor se concentran los datos?”.

- **Medidas de dispersión o variabilidad:** Complementan a las anteriores indicando qué tan dispersos o concentrados están los datos en torno a la tendencia central. La forma más simple de medir la dispersión es el **rango**, que es la diferencia entre el valor máximo y mínimo observados. Sin embargo, el rango también puede verse afectado por valores extremos poco representativos. Por eso se usan medidas más robustas como los **cuartiles**: por ejemplo, el **rango intercuartílico (IQR)** es la diferencia entre el tercer cuartil (Q_3 , percentil 75) y el primer cuartil (Q_1 , percentil 25), abarcando el 50% central de la distribución. Los cuartiles permiten construir el conocido **resumen de cinco números**: mínimo, Q_1 , mediana (Q_2), Q_3 y máximo, que ofrecen una descripción compacta de la distribución. Otra medida fundamental es la **varianza**, que cuantifica la dispersión promedio respecto a la media (matemáticamente, la media de los cuadrados de las desviaciones $(x_i - \bar{x})^2$). Su raíz cuadrada es la **desviación estándar**, expresada en las mismas unidades que la variable original; esta indica, grosso modo, el promedio de distancia de los datos a su media. Una desviación estándar alta implica datos muy esparcidos; una baja indica que los valores están más agrupados alrededor de la media. Estas medidas responden a: “¿Qué tan dispersos o consistentes son los datos?”. Son útiles, por ejemplo, para identificar outliers: valores que se alejan varios desvíos estándar de la media suelen considerarse atípicos.
- **Medidas de forma:** Dos estadísticas descriptivas de *orden superior* comunes son la **asimetría (skewness)** y la **curtosis**. La fig. 2 muestra las cuatro formas típicas y cómo cada una separa la media de la mediana. La **asimetría** mide el grado de falta de simetría de la distribución; distribuciones con cola larga hacia la derecha (valores altos raros) tienen asimetría positiva, mientras que una cola hacia la izquierda indica asimetría negativa. La **curtosis** mide el grado de apuntamiento de la distribución; una curtosis alta indica colas más pesadas (más valores extremos de lo esperado bajo una distribución normal) y un pico más agudo en el centro. Aunque estos dos no siempre se reportan en un análisis exploratorio básico, pueden ser informativos: por ejemplo, una asimetría notable sugiere probar una transformación (como logarítmica) para normalizar la variable. Muchos programas estadísticos calculan automáticamente skewness y kurtosis como parte de sus resúmenes descriptivos, ayudando a diagnosticar desviaciones de la normalidad.
- **Visualización univariante:** Para interpretar mejor las medidas anteriores, se emplean **gráficos exploratorios**. La fig. 3 identifica cada elemento del diagrama de caja sobre datos reales, y la fig. 4 compara las dos representaciones de una misma variable. El más común para variables numéricas es el **histograma**, que muestra la distribución de frecuencias a lo largo de intervalos (bins). El histograma permite apreciar la forma general: si hay uno o varios picos (modas), si la distribución es simétrica o sesgada, si presenta colas largas, etc. Otra visualización muy útil es el **diagrama de caja y bigotes (boxplot)**, que resume visualmente el cinco-números de la variable. En un **boxplot**, la caja central abarca de Q_1 a Q_3 (el IQR), con una línea interna marcando la mediana. Los “bigotes” suelen extenderse hasta 1.5 veces el IQR desde cada cuartil, indicando el rango típico de dispersión; cualquier punto fuera de ese rango se marca individualmente como posible **outlier**. El boxplot, por tanto, revela rápidamente la posición de la mediana (y por tanto asimetría si no está centrada), el grado de dispersión (longitud de la caja y bigotes) y la presencia de valores atípicos. Por ejemplo, una caja muy alargada indicaría alta variabilidad, mientras que puntos aislados fuera de los bigotes alertan de observaciones inusuales. Además, si se colocan varios boxplots en paralelo (por ejemplo, una para cada categoría de un factor), es posible comparar distribuciones de una variable numérica entre distintos grupos (ver sección de análisis bivariado).

En resumen, el análisis univariado combina **estadísticos descriptivos** (media, mediana, cuartiles, etc.) con **visualizaciones** (histogramas, diagramas de caja, gráficos de barras) para brindar una comprensión completa de cada atributo por separado. Esta etapa permite detectar problemas univariados en los datos (p. ej., distribuciones muy sesgadas, necesidad de transformaciones, presencia de muchos valores faltantes o constantes) antes de avanzar al examen de relaciones entre variables.

■ Snippet (Python): histograma y boxplot

```
1 import matplotlib.pyplot as plt
```




Figura 2: Las cuatro formas que conviene reconocer de un vistazo. En una distribución simétrica media y mediana coinciden, y cualquiera de las dos resume bien el centro.

En cuanto aparece asimetría dejan de coincidir: la cola arrastra a la media hacia ella, mientras la mediana se queda donde está la masa de los datos. Por eso ante asimetría marcada la mediana es el resumen más honesto del valor típico.

El caso bimodal es el más traicionero: la media cae en el valle, entre las dos modas, señalando un valor que casi ningún caso toma. Es la situación donde un promedio no describe a nadie, y donde conviene preguntarse si el conjunto mezcla dos poblaciones distintas.




Figura 3: Cada elemento del diagrama de caja, señalado sobre datos reales. La caja abarca del primer al tercer cuartil, de modo que su ancho es el rango intercuartílico y contiene por construcción al 50 % central de las observaciones. La línea interior marca la mediana, y su posición dentro de la caja revela la asimetría: acá aparece descentrada hacia la izquierda, lo que indica cola hacia la derecha.

Los bigotes no llegan al mínimo y al máximo del conjunto, sino hasta el dato más extremo que todavía cae dentro de 1,5 veces el IQR desde el borde de la caja. Todo lo que queda más allá se dibuja como punto individual, y son los cuatro que se ven a la derecha.

Conviene subrayar que ese criterio marca **candidatos** a valor atípico, no sentencias. El factor 1,5 es una convención, no el resultado de una prueba estadística: un punto señalado puede ser un error de carga, pero también una observación legítima y valiosa. Lo que el diagrama hace es indicar dónde mirar.

```

2 import seaborn as sns
3
4 pinguinos = sns.load_dataset("penguins").dropna()
5 col = "body_mass_g"
6
7 fig, (ax_h, ax_b) = plt.subplots(
8     2, 1, sharex=True, figsize=(7, 4),
9     gridspec_kw={"height_ratios": [3, 1]},
10 )
11 ax_h.hist(pinguinos[col], bins=32, alpha=0.8)
12 ax_h.set_ylabel("Frecuencia")
13
14 ax_b.boxplot(pinguinos[col], vert=False, widths=0.5)
15 ax_b.set_yticks([])
16 ax_b.set_xlabel("Masa corporal (g)")
17
18 plt.show()

```

Análisis Bivariado: Tablas de Contingencia, Correlaciones y Visualización de Relaciones

Basado en Hair et al. (2019); McKinney (2022)

El **análisis bivariado** se centra en entender la relación entre dos variables. Esto implica utilizar herramientas diferentes según el tipo de variables involucradas (numéricas o categóricas) y la naturaleza de su posible asociación. Examinemos por separado algunos casos típicos:

- **Relación entre dos variables categóricas:** Tablas de contingencia y Test de Chi-cuadrado. Cuando ambos atribu-




Figura 4: Dos lecturas complementarias de una sola variable. El histograma muestra la forma completa: acá se ve que la masa corporal no es unimodal sino que insinúa dos concentraciones, lo que anticipa que la muestra mezcla especies de tamaños distintos.

El diagrama de caja de abajo, alineado sobre el mismo eje, resume esa misma distribución en cinco números y marca los candidatos a atípico. Gana en comparabilidad —permite poner muchos grupos uno al lado del otro— y pierde la forma: sobre este conjunto, la bimodalidad que el histograma hace evidente resulta invisible en la caja. Cuando el objetivo es entender una variable conviene mirar los dos.

tos son cualitativos (categóricos), la forma estándar de resumir su relación es mediante una **tabla de contingencia**. También conocida como tabla cruzada o *cross-tabulation*, es una **estructura de datos tabular que muestra la distribución de frecuencia conjunta de dos o más variables categóricas**. En esta tabla, las categorías de una variable definen las filas y las de la otra las columnas. Para construirla, se identifican las variables a analizar, se listan todas sus categorías y luego se cuenta el número de veces que cada combinación de categorías aparece en los datos. Cada celda de la tabla muestra esta frecuencia (recuento), conocida como **frecuencia observada**, de los casos que pertenecen a esa combinación específica.

Una **tabla de contingencia** —también llamada tabla cruzada o *cross-tabulation*— es la estructura que muestra la **distribución de frecuencia conjunta** de dos variables categóricas: las filas son las categorías de una y las columnas las de la otra, y cada celda contiene cuántas veces aparecen juntas esas dos categorías en los datos.

Armarla supone cuatro pasos:

1. **Identificar las variables categóricas** que se quieren cruzar.
2. **Determinar las categorías** de cada una: si el atributo A tiene c valores distintos y el B tiene r , la tabla será de $r \times c$.
3. **Contar las ocurrencias conjuntas** de cada combinación. Esas son las **frecuencias observadas**.
4. **Calcular las frecuencias esperadas**, que son las que habría en cada celda si las dos variables fueran independientes. Este paso es opcional para describir, pero indispensable para la prueba estadística que sigue.

Por ejemplo, si analizamos la relación entre *género* y *preferencia de lectura*, una tabla de contingencia 2×2 podría verse así:

	Hombre	Mujer	Total (Marginal de Fila)
Ficción	250	200	450
No Ficción	50	1000	1050
Total (Marginal de Columna)	300	1200	1500 (Total General)

Estas tablas permiten identificar a simple vista posibles dependencias o asociaciones: si ciertas combinaciones ocurren mucho más (o menos) de lo esperado, sugiere una relación. Sin embargo, para determinar formalmente si esta asociación es estadísticamente significativa, se utiliza el **test de chi-cuadrado** (χ^2), también conocido como el **estadístico de Pearson** χ^2 .

El test de chi-cuadrado se basa en la **comparación de las frecuencias observadas en la tabla con las frecuencias que se esperarían si las variables fueran completamente independientes**. La prueba contrasta dos hipótesis: * **H0 (Hipótesis Nula)**: Las dos variables son independientes; no hay correlación entre ellas y cualquier diferencia observada se debe al azar. * **H1 (Hipótesis Alternativa)**: Las dos variables son estadísticamente correlacionadas; existe una asociación significativa entre ellas.

Para realizar la prueba, se calcula el estadístico χ^2 sumando las desviaciones cuadradas entre los valores observados y esperados para cada celda. La magnitud de este valor, junto con los **grados de libertad** (calculados como $(n_{\text{filas}} - 1) \times (n_{\text{columnas}} - 1)$), se utiliza para obtener un p-valor. Si el **valor χ^2 calculado es grande** y el p-valor asociado es menor que un **nivel de significancia** predefinido (ej. 5%), se **rechaza la hipótesis nula (H0)**. Esto significa que se concluye que las variables están **estadísticamente correlacionadas**. Un valor χ^2 grande, por tanto, indica una **fuerte asociación**.

La utilidad de esta prueba va más allá de la simple confirmación de una correlación. En el preprocesamiento de datos, es fundamental para la **selección de atributos (feature selection)**, permitiendo identificar qué predictores categóricos tienen una relación significativa con la variable objetivo antes de incluirlos en un modelo. También se aplica en técnicas como la **discretización automática de atributos numéricos** o para encontrar las reglas de clasificación más “fuertes” en un conjunto de datos.

Conviene retener un tercer uso, menos evidente: el estadístico χ^2 se emplea en el **preprocesamiento** como criterio para la **discretización automática de atributos numéricos**, decidiendo dónde conviene cortar un rango continuo según qué particiones quedan más asociadas con la variable de interés.

- **Visualización:** La fig. 5 muestra la tabla anterior como mapa de calor, primero con las frecuencias observadas y después con los residuos de Pearson, que es donde se hace visible la asociación. Las asociaciones entre variables categóricas también pueden visualizarse con **gráficos de barras agrupadas o apiladas**, mostrando, por ejemplo, para cada categoría de la primera variable, la distribución porcentual en la segunda. Otra opción es el **mosaico plot** o un **heatmap de frecuencias**, donde cada celda de la tabla se representa con un recuadro cuyo tamaño o color es proporcional a la frecuencia. En el gráfico de mosaico, por ejemplo, cada rectángulo representa una celda de la tabla y su área refleja la proporción de casos; diferencias visibles en las áreas respecto a la independencia esperada revelan la asociación. Estas visualizaciones complementan la tabla numérica y el análisis estadístico, facilitando la detección de patrones de asociación de manera intuitiva.
- **Relación entre dos variables numéricas: Correlación y dispersión.** Cuando ambas variables son cuantitativas, el interés suele estar en **qué tan linealmente relacionadas están**. La medida clásica es el **coeficiente de correlación de Pearson**, definido entre -1 y 1. Este coeficiente (r) cuantifica el grado en que, al *aumentar* una variable, la otra tiende sistemáticamente a *aumentar* (correlación positiva, $r > 0$) o a *disminuir* (correlación negativa, $r < 0$). Un valor r cercano a 0 sugiere que no hay relación lineal apreciable. Por ejemplo, $r = 0.8$ indicaría que las dos variables numéricas tienen una asociación positiva fuerte, mientras que $r = -0.5$ indica una relación inversa moderada (a valores altos de una corresponden valores bajos de la otra). Es importante recordar que **correlación no implica causalidad**: incluso si encontramos una correlación alta entre X y Y, esto no significa que X cause cambios en Y o viceversa; podría haber otros factores involucrados. Además, la correlación de Pearson captura relaciones lineales; es posible que dos variables tengan relación no lineal (por ejemplo, curvilínea) y aun así su coeficiente lineal sea cercano a 0. Por ello, es buena práctica complementar el análisis numérico con inspección visual.

Visualización: la herramienta fundamental es el **gráfico de dispersión (scatter plot)**, que representa cada par de valores (x_i, y_i) como un punto en un plano cartesiano (X en el eje horizontal, Y en el vertical). Este gráfico permite *ver* la relación: si los puntos tienden a alinearse aproximadamente en una dirección ascendente, indica correlación positiva; si la nube de puntos se inclina hacia abajo, correlación negativa; si los puntos están dispersos sin forma alguna, posiblemente no haya correlación. La fig. 10 muestra un conjunto de diagramas de dispersión entre pares de variables donde es fácil distinguir los casos de **alta correlación positiva** (puntos alineados en un patrón lineal ascendente), **ausencia de relación** (puntos dispersos al azar) y **relación negativa**. El scatter plot también revela posibles **relaciones no lineales** (por ejemplo, una forma curva) que no serían evidentes con una medida lineal como Pearson. Adicionalmente, ayuda a detectar **outliers**




Figura 5: La misma tabla de contingencia, leída de dos formas. A la izquierda, las frecuencias observadas con el color codificando la magnitud: se ve enseguida que la celda mujer/no ficción domina el conjunto, pero eso solo dice que hay más mujeres y más lectores de no ficción.

A la derecha está la información que importa. El residuo de Pearson mide, celda por celda, cuánto se aparta lo observado de lo que cabría esperar si las dos variables fueran independientes, en unidades de desvío. El color divergente separa los dos sentidos: rojo donde hay más casos de los esperados, azul donde hay menos, blanco donde el dato coincide con la hipótesis de independencia.

El patrón en diagonal es la forma visual de la asociación, y es lo que el estadístico χ^2 resume en un solo número. La figura muestra además de dónde viene ese número: son las celdas de los extremos las que lo producen.

bivariados: puntos que se alejan del patrón general. En análisis exploratorio, es común dibujar una línea de tendencia o calcular r para apoyar la impresión visual. De hecho, visualizar la nube de puntos suele ser el primer paso antes de confiar en la métrica numérica, ya que uno puede descubrir patrones peculiares (p. ej., relaciones en forma de U) o segmentos diferenciados de datos.

- **Relación entre una variable categórica y una numérica:** En este caso, típicamente se desea comparar la distribución de la variable numérica a través de los distintos grupos definidos por la variable categórica. Por ejemplo, comparar si la *edad* (numérica) difiere según *género* (categórico). Estadísticamente, esto se aborda con comparaciones de medias (t-test, ANOVA) en análisis inferencial. En EDA descriptivo, se puede examinar cada grupo por separado con medidas univariadas y luego contrastarlas. Un indicador simple es listar la media y mediana de la variable numérica en cada categoría. Si difieren notablemente, podría haber un efecto de grupo. Sin embargo, es más ilustrativo usar visualizaciones específicas.

Visualización: el **gráfico de cajas por grupos** es ideal. Consiste en dibujar un *boxplot* de la variable numérica para cada categoría, uno al lado del otro, facilitando la comparación directa. Por ejemplo, un boxplot de *ingresos* para distintas regiones: se podrá observar si una región tiene la mediana de ingresos más alta, o si otra muestra más variabilidad (caja más grande) o presencia de outliers. La fig. 6 muestra un diagrama de caja del porcentaje de propina por día de la semana, donde se aprecian las diferencias de mediana y de dispersión entre días. Alternativamente, para variables categóricas con pocas categorías, **diagramas de violín** (variación del boxplot que incluye la densidad estimada) o **gráficos de barras con error** (mostrando la media por categoría y su intervalo de confianza) pueden emplearse. Lo importante en análisis exploratorio es ver si existen *diferencias sistemáticas* entre grupos que puedan justificar un análisis más profundo o un modelo que las tenga en cuenta.

En síntesis, el análisis bivariado nos permite descubrir **asociaciones o comparaciones clave entre pares de variables:** asociaciones categóricas a través de tablas de contingencia, relaciones lineales o no lineales entre numéricas mediante correlación y gráficas de dispersión, y diferencias de distribución de una numérica según grupos categóricos vía boxplots comparativos. Estas exploraciones ayudan a generar hipótesis (*¿estarán X e Y relacionados? ¿Influirá el grupo Z en el valor de Y?*), detectar factores importantes y decidir qué variables podrían incluirse en modelos predictivos posteriores.




Figura 6: El diagrama de caja paralelo es la forma canónica de cruzar una variable categórica con una numérica. Cada caja resume la distribución del porcentaje de propina dentro de un día, y ponerlas sobre el mismo eje convierte la comparación en una lectura directa: se comparan medianas mirando la línea, dispersiones mirando el ancho de la caja, y asimetrías mirando dónde cae la mediana dentro de ella.

Acá los cuatro días quedan notablemente parecidos en su centro, y lo que los diferencia es la dispersión y la cantidad de casos extremos. Es un resultado que una tabla de promedios por día ocultaría por completo.

Reproduce la figura 9-28 de McKinney (2022) sobre el mismo conjunto de datos.

Snippet (Python): contingencia + chi-cuadrado

```
1 import pandas as pd
2 from scipy.stats import chi2_contingency
3
4 # La tabla de contingencia de la seccion anterior, cargada directamente.
5 tabla = pd.DataFrame(
6     [[250, 200], [50, 1000]],
7     index=["Hombre", "Mujer"],
8     columns=["Ficcion", "No ficcion"],
9 )
10
11 chi2, p, gl, esperado = chi2_contingency(tabla)
12 print(f"chi2 = {chi2:.1f}    gl = {gl}    p-valor = {p:.3g}")
13 print("\nFrecuencias esperadas bajo independencia:")
14 print(pd.DataFrame(esperado, index=tabla.index, columns=tabla.columns).round(1))
```

Snippet (Python): correlación + recta de tendencia

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 import seaborn as sns
4
5 pinguinos = sns.load_dataset("penguins").dropna()
6 x = pinguinos["flipper_length_mm"]
7 y = pinguinos["body_mass_g"]
8
9 r = x.corr(y)
10 m, b = np.polyfit(x, y, 1)
11
12 plt.scatter(x, y, alpha=0.6)
```

```

13 # La recta se dibuja sobre una grilla ordenada: si se usara x tal cual, matplotlib
14 # uniría los puntos en el orden del DataFrame y la "recta" saldría en zigzag.
15 xs = np.linspace(x.min(), x.max(), 100)
16 plt.plot(xs, m * xs + b)
17 plt.title(f"Largo de aleta vs masa corporal (r = {r:.3f})")
18 plt.xlabel("Largo de la aleta (mm)")
19 plt.ylabel("Masa corporal (g)")
20 plt.show()

```

Snippet (Python): boxplots por grupo

```

1 import matplotlib.pyplot as plt
2 import seaborn as sns
3
4 tips = sns.load_dataset("tips")
5 tips["pct_propina"] = tips["tip"] / tips["total_bill"]
6
7 tips.boxplot(column="pct_propina", by="day", rot=0)
8 plt.title("Porcentaje de propina por día")
9 plt.suptitle("")
10 plt.xlabel("Día")
11 plt.ylabel("Propina / cuenta")
12 plt.show()

```

Análisis Multivariado: Visualización de Datos de Alta Dimensión

Basado en Hair et al. (2019); McKinney (2022)

El **análisis multivariado exploratorio** busca comprender simultáneamente las relaciones entre más de dos variables. A medida que aumenta el número de variables, se vuelve complejo apreciar patrones con herramientas bivariadas simples, por lo que se requieren enfoques que permitan visualizar o resumir la estructura en espacios de mayor dimensión. Dos técnicas clásicas de visualización exploratoria multivariada son la **matriz de dispersión** y las **coordenadas paralelas**, las cuales proporcionan perspectivas complementarias de datos de alta dimensión.

- **Matriz de dispersión (Scatterplot matrix o pairs plot):** Es esencialmente una cuadrícula que muestra todos los gráficos de dispersión bivariados posibles entre un conjunto de variables numéricas. Si tenemos, por ejemplo, 4 variables numéricas, la matriz de dispersión presentará una grilla de 4x4 donde en la fila i columna j se ubica el scatter plot de la variable i vs la j (normalmente se usa solo la mitad inferior o superior de la matriz porque es simétrica). En la diagonal frecuentemente se colocan histogramas o distribuciones de cada variable individual. La utilidad de esta visualización es que **permite examinar de un vistazo todas las relaciones por pares entre variables**, facilitando identificar cuáles parejas de variables están fuertemente correlacionadas, cuáles parecen no relacionadas, o si alguna combinación exhibe patrones no lineales. Por ejemplo, si tenemos variables X_1, X_2, X_3 , la matriz de dispersión mostrará gráficos X_1 vs X_2 , X_1 vs X_3 , X_2 vs X_3 , etc., pudiendo inmediatamente notarse, digamos, que X_1 y X_2 tienen puntos alineados (alta correlación), mientras X_2 vs X_3 los puntos están dispersos caóticamente (correlación cercana a 0). Hair et al. (2019) destacan que la scatterplot matrix brinda un método rápido para evaluar la **fuerza y forma de cualquier relación bivariada** y a la vez **identificar patrones no lineales** que podrían pasar desapercibidos si uno solo mirara coeficientes de correlación lineal. En contextos de EDA, bibliotecas como *pandas* o *seaborn* en Python ofrecen funciones para generar fácilmente matrices de dispersión (llamadas *pairplot* en *seaborn*), incluyendo histogramas en la diagonal y hasta densidades bivariadas. La fig. 7 es un ejemplo de *pair plot* donde cada celda de la diagonal lleva un *kde* (estimación de densidad) univariado, y los diagramas de dispersión fuera de la diagonal permiten apreciar correlaciones positivas, negativas o nulas entre todas las combinaciones de variables.
- **Coordenadas paralelas (profile plot o parallel coordinates):** Es una técnica de visualización para datos multivariados donde cada observación (caso) se representa como una línea que atraviesa múltiples ejes verticales paralelos. Cada eje vertical corresponde a una variable, con su escala de valores; la posición donde la línea cruza cada eje




Figura 7: La matriz de dispersión resuelve el problema de mirar muchas relaciones a la vez. Cada celda fuera de la diagonal es el diagrama de dispersión de un par de variables; la matriz es simétrica, de modo que la mitad inferior repite la superior con los ejes intercambiados. En la diagonal, donde una variable se cruzaría consigo misma, va su distribución univariada.

Colorear por especie transforma la lectura. Sin color, el par alto del pico contra largo de la aleta parece una nube dispersa y hasta con pendiente negativa; con color, se ve que son dos grupos bien separados, cada uno con pendiente positiva. Es un caso de la paradoja de Simpson visible a simple vista.

El límite es de escala: con k variables hay $k(k-1)/2$ paneles distintos, así que más allá de unas diez la matriz deja de ser legible.

equivale al valor de esa observación en la variable correspondiente, y uniendo esos puntos para todos los ejes se obtiene una *polilínea* representativa de la *configuración completa de valores* de esa observación en todas las variables. Al trazar muchas observaciones juntas, se puede visualizar el “perfil” de cada caso y compararlo con otros. Las coordenadas paralelas son útiles para **detectar conglomerados naturales de observaciones con patrones similares** y también para **identificar outliers multivariados**, aquellos cuya combinación de valores es muy diferente a la del resto. Por ejemplo, supongamos que tenemos 5 variables medidas en pacientes. En el gráfico de coordenadas paralelas tendríamos 5 ejes verticales; cada paciente se dibuja como una línea que va pasando por sus valores de altura, peso, presión arterial, colesterol, etc. Si un paciente es un outlier multivariado (por ejemplo, valores extremos en varias mediciones que lo hacen atípico en el perfil general), su línea aparecerá claramente apartada del “haz” denso de líneas correspondientes a la mayoría de pacientes. De igual modo, si existen grupos naturales (p. ej., dos subtipos de individuos con características diferenciadas), podríamos ver dos patrones predominantes de líneas. Hair et al. (2019) refieren a este tipo de gráfico también como **profile diagram**, señalando que es un método simple para revisar datos en busca de outliers antes de un análisis de clusters, por ejemplo. Cada línea representa un objeto (ej. un respondente en una encuesta), de modo que **líneas con formas muy distintas a las demás indican observaciones atípicas**. Una limitación de las coordenadas paralelas es que pueden volverse visualmente recargadas si hay muchísimos casos; en tales situaciones se puede subsamplear casos, o utilizar transparencia en las líneas para apreciar densidades.




Figura 8: Las coordenadas paralelas cambian el truco: en vez de gastar una dimensión de la página por variable, ponen todas las variables como ejes verticales lado a lado. Cada individuo deja de ser un punto y pasa a ser una polilínea que cruza los cuatro ejes por el valor que le corresponde. Como las escalas originales son incomparables —milímetros contra gramos—, cada eje se normaliza al intervalo $[0, 1]$; sin ese paso el gráfico queda dominado por la variable de mayor rango.

Lo que la técnica hace visible son los *perfiles*: las líneas gruesas son el promedio de cada especie, y se lee de un golpe que Gentoo tiene pico largo pero poco profundo, aletas largas y mucha masa, mientras Adelie invierte casi el patrón. Un cruce de líneas entre dos ejes indica correlación negativa entre esas dos variables; un haz de líneas paralelas, correlación positiva.

La línea punteada sigue al individuo de mayor masa y muestra el otro uso de la técnica: un caso que se aparta del haz en varios ejes a la vez es un atípico multivariado, algo que ningún diagrama de caja por variable habría marcado.

La fig. 8 ilustra la técnica sobre los cuatro atributos del conjunto de pingüinos, y la fig. 9 agrega una tercera vía: el mapa de calor de la matriz de correlación, que reordena las variables por similitud y hace aparecer los bloques redundantes como cuadrados sobre la diagonal.

En conjunto, tanto la matriz de dispersión como las coordenadas paralelas permiten abordar la complejidad de datos multivariados de forma visual. La primera se centra en relaciones bivariadas exhaustivamente, mientras la segunda intenta mostrar cada observación en el contexto de todas las variables simultáneamente. En análisis exploratorio moderno

también se emplean técnicas derivadas o complementarias, como **grafos de calor (heatmaps) de matrices de correlaciones** (que muestran todas las correlaciones entre variables con una codificación de color), o **gráficos tridimensionales interactivos** cuando se analizan tres variables conjuntamente. Sin embargo, para más de 3 dimensiones, las visualizaciones directas se vuelven difíciles, y es allí donde entran en juego métodos de reducción de dimensionalidad, tema que exploraremos a continuación.




Figura 9: El mapa de calor de la matriz de correlación convierte una tabla de números en un patrón. El color divergente separa los dos sentidos de la asociación y deja el blanco para la ausencia de relación, de modo que la intensidad se lee como magnitud y el tono como signo.

El agregado importante es el dendrograma de los márgenes: en lugar de dejar las variables en el orden arbitrario en que vienen en el archivo, las reordena poniendo juntas a las que se comportan parecido. Así los bloques de variables redundantes aparecen como cuadrados de color uniforme sobre la diagonal, sin que haya que buscarlos leyendo celda por celda.

Acá el bloque de largo de aleta y masa corporal, con correlación 0,87, es exactamente el tipo de redundancia que después justifica reducir dimensiones o descartar una de las dos.

Snippet (Python): matriz de dispersión & coordenadas paralelas

```

1 import matplotlib.pyplot as plt
2 import seaborn as sns
3 from pandas.plotting import scatter_matrix, parallel_coordinates
4
5 pinguinos = sns.load_dataset("penguins").dropna()
6 num_cols = pinguinos.select_dtypes("number").columns
7
8 scatter_matrix(pinguinos[num_cols], figsize=(8, 8), diagonal="kde")
9 plt.suptitle("Matriz de dispersión")
10 plt.show()
11
12 # Las coordenadas paralelas necesitan la columna de clase DENTRO del DataFrame, y las
13 # variables en una escala común: sin normalizar, el eje de mayor rango domina el
14 # gráfico.
15 z = pinguinos[num_cols].apply(lambda c: (c - c.min()) / (c.max() - c.min()))
16 z["species"] = pinguinos["species"].to_numpy()

```



```

17 parallel_coordinates(z, "species", alpha=0.3)
18 plt.title("Coordenadas paralelas")
19 plt.ylabel("Valor normalizado a [0, 1]")
20 plt.show()

```

Coeficientes de correlación

Basado en Han, Pei y Tong (2022); Kuhn y Johnson (2020); McKinney (2022)

¿Qué son? Los coeficientes de correlación son **medidas estadísticas que cuantifican la fuerza y la dirección de la relación entre dos o más variables**. Permiten descubrir patrones, tendencias y anomalías en los datos.

¿Cuáles existen? (al menos los más comunes) Existen varios coeficientes y medidas de correlación, cada uno adecuado para diferentes tipos de datos y relaciones:

- **Coeficiente de Correlación (Pearson)**: Se utiliza para datos numéricos y mide la **correlación lineal**. El cálculo del área es función del diámetro, lo que resulta en una alta correlación entre medidas relacionadas como el área y el diámetro.
- **Lift**: Una medida simple de correlación utilizada para **itemsets**. Se basa en la probabilidad de que los itemsets ocurran juntos versus la probabilidad de que ocurran de forma independiente.
- **Medida Chi-cuadrado (χ^2)**: Utilizada para determinar la **correlación entre atributos nominales (categóricos)**. Se basa en la comparación de los valores observados y esperados en una tabla de contingencia.
- **all_confidence**: Mide la relación entre itemsets, con valores que van de 0 a 1, donde un valor más alto indica una relación más estrecha. También es el mínimo de las confianzas de las dos reglas de asociación relacionadas con los itemsets A y B ($A \rightarrow B$ y $B \rightarrow A$).
- **Medida de Kulczynski (Kulc)**: Una medida de interés utilizada para evaluar la relación entre patrones, especialmente útil para identificar patrones negativamente correlacionados.
- **Similitud Coseno**: Se utiliza para medir la similitud entre vectores de datos, especialmente para **vectores largos y dispersos** como los vectores de frecuencia de términos en documentos. Se enfoca en las palabras que los documentos tienen en común y sus frecuencias, ignorando las coincidencias de cero.
- **Correlación de Rangos**: Se refiere a la correlación que se basa en el orden de los valores (rangos) en lugar de los valores numéricos exactos, lo que la hace útil para capturar relaciones **monotónicas no lineales**.

Qué miden: correlación lineal frente a correlación monotónica Los coeficientes de correlación miden la **interdependencia estadística entre variables**.

- **Correlación Lineal**: Mide la fuerza y dirección de una **relación lineal** entre dos variables numéricas. Un aumento en una variable está asociado con un aumento o disminución constante en la otra. El coeficiente de Pearson es un ejemplo clave.
- **Correlación Monotónica**: Mide si las variables tienden a moverse en la misma dirección general, pero no necesariamente a una tasa constante. Es decir, si una variable aumenta, la otra tiende a aumentar (o disminuir), pero la forma exacta de la relación no tiene por qué ser una línea recta. Los métodos basados en rangos son resistentes a distribuciones asimétricas o valores atípicos, lo que sugiere su capacidad para capturar relaciones monotónicas.

¿Cuáles son sus ecuaciones? (o cómo funcionan) Las ecuaciones de algunos de los coeficientes comunes son:

- **Lift**: Para los itemsets A y B, el Lift se calcula como: $P(A \cup B) / (P(A) \cdot P(B))$.
- **Medida Chi-cuadrado (χ^2)**: Para una tabla de contingencia, se calcula como la suma de los cuadrados de la diferencia entre la frecuencia observada (O) y la frecuencia esperada (E) para cada celda, dividida por la frecuencia esperada: $\chi^2 = \sum (\text{Observado} - \text{Esperado})^2 / \text{Esperado}$.
- **all_confidence**: Para los itemsets A y B, se define como: $\sup(A \cup B) / \max\{\sup(A), \sup(B)\}$, que es equivalente a $\min\{P(A|B), P(B|A)\}$.
- **Medida de Kulczynski**: Para los itemsets A y B, se calcula como: $(P(B|A) + P(A|B)) / 2$.

¿Cómo se interpretan? La interpretación de los valores de correlación depende del coeficiente utilizado:

- **Coeficiente de Correlación (Pearson):**
- Valores cercanos a **+1** indican una **fuerte correlación lineal positiva** (ambas variables aumentan o disminuyen juntas).
- Valores cercanos a **-1** indican una **fuerte correlación lineal negativa** (una variable aumenta mientras la otra disminuye).
- Valores cercanos a **0** indican una **correlación lineal débil o nula**.
- **Lift:**
- **Lift < 1:** Indica una **correlación negativa**; los itemsets A y B tienden a no ocurrir juntos más de lo esperado por casualidad.
- **Lift = 1:** Indica **independencia**; la ocurrencia de A no influye en la ocurrencia de B.
- **Lift > 1:** Indica una **correlación positiva**; los itemsets A y B tienden a ocurrir juntos más de lo esperado por casualidad.
- **Medida Chi-cuadrado (χ^2):** Un valor χ^2 grande sugiere una **fuerte asociación o correlación** entre las variables nominales. Si el valor χ^2 es lo suficientemente grande como para rechazar la hipótesis nula de independencia (basado en un nivel de significancia y grados de libertad), entonces las variables se consideran estadísticamente correlacionadas.
- **all_confidence:** Cuanto más alto sea el valor (cercano a 1), más estrecha es la relación entre los itemsets A y B.
- **Medida de Kulczynski:** Se utiliza para identificar patrones que están **negativamente correlacionados**, lo que puede ser contraintuitivo con otras medidas de asociación que solo detectan relaciones positivas. Se recomienda usar Kulc junto con la relación de desequilibrio (imbalance ratio) para obtener una imagen clara.

Ejemplos de gráficos con distribuciones con distintas correlaciones y los valores de correlación Los **gráficos de dispersión (scatter plots)** son herramientas visuales fundamentales para inspeccionar las relaciones bivariadas entre datos. Permiten una inspección visual útil en el preprocesamiento de datos.

Dos recursos complementarios permiten leer la estructura de correlación de un conjunto de datos. El primero es el propio gráfico de dispersión entre dos variables, que muestra la forma concreta de la relación. El segundo es la **matriz de correlación**, útil para observar simultáneamente las relaciones entre múltiples predictores: el color o la intensidad de cada celda representa la fuerza de la correlación, de modo que los bloques de variables redundantes se hacen visibles de un vistazo.

La fig. 10 recorre los casos. Una **correlación positiva fuerte** se presenta como una nube estrecha alrededor de una recta ascendente; una **negativa fuerte**, alrededor de una descendente. Una **correlación débil o nula** aparece como una nube sin dirección. El quinto panel muestra el caso que más conviene tener presente: una dependencia perfecta pero **no lineal**, donde el coeficiente de Pearson cae a cero pese a que las dos variables están completamente determinadas una por la otra. El sexto ilustra una **relación monotónica no lineal**, donde Pearson subestima la fuerza de la asociación y el coeficiente de Spearman la recupera.

¿Se mide alguna probabilidad? ¿Cómo se interpreta? Sí, en el contexto de la correlación y las asociaciones, se miden y utilizan probabilidades:

- **Lift:** Este coeficiente se calcula directamente a partir de las **probabilidades conjuntas y marginales** de los itemsets. Su interpretación se basa en la desviación de la independencia probabilística.
- **Reglas de Asociación (Soporte y Confianza):** El **soporte (s)** de una regla $A \Rightarrow B$ es el porcentaje de transacciones que contienen A y B juntos, que se interpreta como la **probabilidad $P(A \wedge B)$** . La **confianza (c)** es el porcentaje de transacciones que contienen A y que también contienen B, lo que se interpreta como la **probabilidad condicional $P(B|A)$** .
- **Test Chi-cuadrado (χ^2):** Aunque el valor χ^2 no es una probabilidad, el test genera un **p-valor**, que es una probabilidad. El p-valor indica la **probabilidad de observar una asociación tan fuerte (o más fuerte) por puro azar**, asumiendo que no hay una relación real entre las variables (la hipótesis nula).
- Un **p-valor pequeño** (comúnmente < 0.05) sugiere que la diferencia observada es **estadísticamente significativa** y no se debe al azar, lo que lleva a rechazar la hipótesis nula de independencia y concluir que existe una correlación.




Figura 10: Qué mide y qué no mide el coeficiente de correlación de Pearson. Los cuatro primeros paneles recorren el caso para el que fue pensado: una relación lineal cuya nube se estrecha alrededor de la recta a medida que r se acerca a 1 en valor absoluto, y cuyo signo indica el sentido. Con $r \approx 0$ la nube no tiene dirección.

Los dos últimos paneles muestran el límite. En el quinto hay una dependencia perfecta —y es función de x — y sin embargo $r \approx 0$: Pearson mide asociación **lineal**, y una parábola simétrica no la tiene. Un analista que se guiara solo por el coeficiente concluiría que las variables no están relacionadas.

El sexto caso es monotónico pero curvo. Ahí Pearson subestima la fuerza de la relación mientras el coeficiente de Spearman, que trabaja sobre los rangos y no sobre los valores, la captura casi por completo. La lección práctica es la misma en los seis: el coeficiente se interpreta mirando el diagrama de dispersión, nunca solo.

Muestreo Inteligente para Grandes Volúmenes de Datos

Basado en Han, Pei y Tong (2022); McKinney (2022)

A medida que los conjuntos de datos crecen en tamaño (millones de filas, por ejemplo), realizar EDA completo sobre todos los datos puede ser costoso o incluso impracticable. El **muestreo inteligente** se refiere a la aplicación de técnicas de selección de subconjuntos representativos de datos con el fin de facilitar el análisis exploratorio en **grandes volúmenes de datos**, manteniendo en lo posible las principales características o patrones del conjunto completo. La idea es que un **buen subconjunto muestral** puede ahorrar tiempo computacional y permitir visualizaciones manejables, sin sacrificar conclusiones (o al menos controlando el error incurrido).

El **muestreo aleatorio simple** es la estrategia base: seleccionar aleatoriamente n registros de un total N . Puede hacerse *sin reemplazo* (SRSWOR: cada elemento se elige a lo sumo una vez) o *con reemplazo* (SRSWR: un mismo elemento podría ser elegido más de una vez, aunque típicamente en grandes N la probabilidad de repeticiones es baja). Extraer una muestra aleatoria de, digamos, 5% de los datos suele acelerar enormemente cualquier exploración, con un costo proporcional al tamaño de la muestra n en lugar de al tamaño total N . De hecho, el costo computacional de manejar la muestra suele crecer linealmente con n , mientras que trabajar con todo el dataset podría crecer linealmente con N o peor, dependiendo de la operación. Dado que $n \ll N$, el ahorro es sustancial. Es por esto que el muestreo se considera una técnica básica de **reducción de datos**: permite representar un dataset grande por uno mucho más pequeño preservando, con cierto error, sus propiedades principales.

Ahora bien, el adjetivo “*inteligente*” implica que muchas veces no basta con tomar un muestreo aleatorio simple, sobre todo si los datos tienen estructuras importantes que queremos respetar en la muestra. Por ejemplo, si una clase minoritaria compone solo 1% de 100 millones de registros, una muestra aleatoria del 1% de los datos podría contener muy pocos ejemplos de esa minoría (incluso podría darse el caso extremo de cero ejemplos). Para evitar distorsiones, se recurre a técnicas de muestreo dirigido:

- En el **muestreo estratificado**, se divide la población en subgrupos o estratos (por ejemplo, por clase, por región geográfica, por periodo temporal), y luego se toma una muestra aleatoria dentro de *cada* estrato. De esta forma se garantiza que la muestra contenga representatividad de todos los tipos de casos. Por ejemplo, estratificando por clase de un modelo de clasificación, podemos asegurarnos de incluir suficientes ejemplos de cada clase según su proporción original. Si los datos están *desbalanceados*, el muestreo estratificado puede inclusive sobremuestrear las categorías raras para facilitar el análisis (aunque eso altere las proporciones, serviría para ciertos propósitos exploratorios).
- En el **muestreo por conglomerados (clusters)**, se particiona la población en grupos naturales o *clusters* (por ejemplo, por cliente, por tienda, por día) y luego se seleccionan algunos clusters completos al azar para analizar. Esta técnica a veces se utiliza por comodidad (se obtienen datos por lotes), pero en exploración puede servir para preservar cierta estructura agrupada. Por ejemplo, si nuestros datos son páginas web y sus visitas diarias, podríamos muestrear 10 días completos en lugar de miles de accesos individuales dispersos; cada día seleccionado retiene la correlación temporal interna.

Una ventaja fundamental del muestreo es que, por la teoría estadística, **es posible estimar el error** que se comete al trabajar con la muestra en lugar de con la población completa. Usando el **teorema del límite central**, podemos determinar qué tamaño de muestra n sería suficiente para estimar agregados (como medias, proporciones) con un margen de error dado y una cierta confianza. En muchos casos, resulta que un tamaño muestral relativamente pequeño (cientos o pocos miles) ya permite estimar características globales de un dataset gigantesco con sorprendente precisión, si la muestra es verdaderamente aleatoria. Además, un enfoque de *refinamiento progresivo* es posible: empezar con una pequeña muestra para exploración rápida, y luego **incrementar el tamaño de la muestra** para afinar conclusiones o capturar patrones más sutiles.

La fig. 11 compara las tres alternativas. En entornos de big data, es común combinar muestreo con herramientas de visualización: por ejemplo, en lugar de graficar 10 millones de puntos en un scatter plot (lo que sería ilegible y pesado de computar), se grafican quizás 100 mil puntos tomados al azar. El gráfico muestreado suele mostrar el mismo patrón general (nube de correlación, forma de la distribución) pero con mucha menos sobrecarga visual.

En conclusión, el muestreo inteligente consiste en **seleccionar subconjuntos de datos de manera planificada** para que el análisis exploratorio sea factible en volumen y tiempo, sin perder tendencias clave. Siempre que se use muestreo, se




Figura 11: El problema del sobretrazado y sus dos soluciones. El panel izquierdo dibuja los 1,2 millones de puntos: donde hay densidad alta las marcas se superponen hasta saturar y la figura se vuelve una mancha. Peor todavía, es una mancha *engañosa*, porque una zona con mil puntos y otra con cien mil se ven exactamente igual. El costo de cómputo y el tamaño del archivo crecen con n sin que la información crezca.

El panel del medio toma una muestra aleatoria de menos del 1 %. La estructura —las dos concentraciones y la relación lineal de la principal— se conserva intacta, con un centésimo del trabajo. Es la razón práctica por la que conviene muestrear antes de explorar: el patrón general sobrevive al muestreo.

El panel derecho usa todos los datos pero cambia la unidad de dibujo: divide el plano en hexágonos y colorea cada uno según cuántos casos contiene. No pierde ninguna observación y recupera lo que el sobretrazado destruía, que es la densidad. Cuando el objetivo es justamente saber dónde se concentran los datos, la agregación es preferible al muestreo.

debe tener en cuenta la posibilidad de error muestral o sesgo de selección; por ello, las conclusiones obtenidas de una muestra conviene validarlas, si es posible, volviendo a la población o usando múltiples muestras. No obstante, como técnica exploratoria, el muestreo es invaluable cuando lidiamos con conjuntos de datos masivos – nos permite aplicar todas las técnicas de EDA discutidas (estadísticos descriptivos, visualizaciones univariadas, scatter plots, etc.) en un **tiempo sublineal en el tamaño del data set**, haciendo abordable lo que de otro modo no lo sería.

| Snippet (Python): muestreo simple y estratificado

```
1 import seaborn as sns
2
3 pinguinos = sns.load_dataset("penguins").dropna()
4
5 # Muestreo aleatorio simple
6 muestra = pinguinos.sample(frac=0.20, random_state=42)
7
8 # Muestreo estratificado: conserva la proporción de cada especie
9 estratificada = (pinguinos
10                  .groupby("species", group_keys=False)[pinguinos.columns]
11                  .apply(lambda g: g.sample(frac=0.20, random_state=42)))
12
13 print("Proporciones en el conjunto completo:")
14 print(pinguinos["species"].value_counts(normalize=True).round(3))
15 print("\nEn la muestra estratificada:")
16 print(estratificada["species"].value_counts(normalize=True).round(3))
```

Reducción de Dimensionalidad y Aplicaciones en la Visualización de Datos

Basado en Han, Pei y Tong (2022); Hair et al. (2019); Zheng y Casari (2018); Kuhn y Johnson (2020)

Cuando los datos contienen una gran cantidad de variables (alta dimensionalidad), el análisis exploratorio enfrenta otro tipo de complejidad: no solo hay más relaciones bivariadas y multivariadas posibles, sino que es difícil visualizar o conceptualizar datos en espacios de muchas dimensiones. La **reducción de dimensionalidad** es un conjunto de técnicas cuyo objetivo es **reducir el número de variables (atributos o características) bajo consideración, reteniendo la mayor cantidad posible de información relevante**. En otras palabras, busca eliminar la “información redundante o poco informativa” mientras conserva los aspectos clave de los datos. Esto resulta útil por varias razones: (a) simplifica y acelera los análisis posteriores, (b) puede mejorar algunos modelos de IA mitigando la *curse of dimensionality*, y (c) permite **visualizar datos complejos proyectándolos en 2 o 3 dimensiones** de manera que estructuras latentes (clústeres, relaciones) se hagan evidentes.

La “Maldición de la Dimensionalidad”

El concepto de “Maldición de la Dimensionalidad” describe los desafíos y problemas que surgen al trabajar con conjuntos de datos que poseen un número muy elevado de variables. Estos problemas pueden afectar significativamente el rendimiento y la interpretabilidad de los modelos.

- **Aumento del costo computacional:** A medida que el número de predictores aumenta, la carga computacional para entrenar un modelo crece exponencialmente, lo que puede llevar a procesos ineficientes y que consumen mucho tiempo.
- **Dispersión de los datos (Esparsidad):** En espacios de alta dimensionalidad, los datos se vuelven inherentemente dispersos. Esto significa que la distancia entre cualquier par de puntos tiende a ser similar, dificultando la identificación de vecinos cercanos y, por ende, de clústeres reales.
- **Dificultad para encontrar patrones:** Los atributos irrelevantes o redundantes pueden ser perjudiciales, causando confusión para los algoritmos de minería y resultando en patrones descubiertos de baja calidad. La medición de distancias entre objetos puede no ser fiable.
- **Riesgo de sobreajuste (Overfitting):** Un mayor número de predictores, especialmente si son poco informativos, incrementa el riesgo de que un modelo se ajuste al ruido de los datos de entrenamiento en lugar de a la señal subyacente, degradando su rendimiento predictivo en datos nuevos.

La fig. 12 mide el fenómeno: a medida que crece la dimensión, la distribución de las distancias entre pares se concentra alrededor de su media, hasta que la noción misma de vecindad deja de tener contenido.

Para superar estos desafíos, la **reducción de dimensionalidad** se vuelve una etapa crucial en el preprocesamiento de datos.

Preprocesamiento: Normalización y Estandarización

Antes de aplicar técnicas como PCA, es fundamental realizar un preprocesamiento de los datos. La **normalización o estandarización** es una técnica de transformación esencial, especialmente para algoritmos sensibles a la magnitud o escala de las variables. El objetivo es escalar los valores de los atributos para que caigan dentro de un rango común.

La necesidad de esta transformación radica en que las unidades de medida pueden afectar el análisis. Atributos con rangos de valores grandes tienden a tener un mayor “peso” en los cálculos de distancia, lo que puede llevar a resultados sesgados. Al normalizar, se asegura que cada atributo contribuya de manera más equitativa.

StandardScaler: Estandarización a media cero y varianza unitaria Una de las técnicas más comunes y recomendadas antes de PCA es la estandarización mediante `StandardScaler`. La fig. 13 muestra el efecto concreto de omitir o aplicar este paso sobre las componentes que el método encuentra. Este proceso transforma los datos para que tengan una **media de 0** y una **desviación estándar de 1**. La transformación se realiza por columna (atributo) aplicando la siguiente fórmula para cada valor x_{ij} del atributo j :

$$x'_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

donde

μ_j es la media y

σ_j es la desviación estándar del atributo j . Esta transformación es vital para PCA, ya que este método busca maximizar la varianza y, por lo tanto, es sensible a las escalas originales de las variables.




Figura 12: La maldición de la dimensionalidad, medida. Cada panel toma 400 puntos distribuidos uniformemente en el hipercubo unitario de dimensión d y grafica la distribución de las distancias entre todos los pares, normalizadas por su media para que las cuatro escalas sean comparables.

En dos dimensiones el histograma es ancho: hay pares muy cercanos y pares muy lejanos, y esa diferencia es lo que permite hablar de vecindad. A medida que d crece, la distribución se comprime alrededor de 1 y el coeficiente de variación cae de forma sostenida. En mil dimensiones prácticamente todos los pares están a la misma distancia.

La consecuencia es concreta y afecta a casi todo el instrumental habitual: cuando las distancias dejan de diferenciarse, el concepto de “vecino más cercano” pierde sentido, y con él pierden poder los métodos que se apoyan en él — k -NN, el agrupamiento por distancia, la detección de atípicos por vecindad—. Es el argumento de fondo por el que reducir dimensiones no es solo una comodidad visual.

```

1  import numpy as np
2  from sklearn.preprocessing import StandardScaler
3
4  # Datos de ejemplo
5  data = np.array([[10, 200],
6                  [15, 250],
7                  [5, 150],
8                  [12, 220]], dtype=float)
9
10 # Aplicar estandarización
11 scaler = StandardScaler()
12 data_estandarizada = scaler.fit_transform(data)
13
14 print("Datos estandarizados:\n", data_estandarizada)
15 print(f"\nMedia: {data_estandarizada.mean(axis=0)}")
16 print(f"\nDesviación estándar: {data_estandarizada.std(axis=0)}")

```

Análisis de Componentes Principales (PCA)

Uno de los métodos de reducción dimensional más conocidos y utilizados es el **Análisis de Componentes Principales (ACP o PCA)**. PCA es una técnica lineal cuyo **objetivo principal** es transformar un conjunto de variables originales posiblemente correlacionadas en un nuevo conjunto de variables no correlacionadas, llamadas **componentes principales**.

Estos componentes se construyen como combinaciones lineales de los atributos originales y se **ordenan por la cantidad de varianza que explican**. El primer componente retiene la mayor varianza posible, el segundo retiene la máxima varianza restante ortogonal al primero, y así sucesivamente. En esencia, PCA busca la dirección en el espacio de datos donde éstos presentan mayor dispersión (primer componente), luego la siguiente dirección ortogonal de mayor dispersión (segundo componente), etc. Si los datos originales presentan fuertes correlaciones, su “información” efectiva reside en menos dimensiones, y PCA las identificará.

Fundamentos Matemáticos El procedimiento de PCA se basa en conceptos de álgebra lineal y estadística:




Figura 13: Por qué el análisis de componentes principales exige estandarizar primero. El método busca las direcciones de máxima varianza, y la varianza depende de las unidades. A la izquierda, la masa corporal se mide en gramos y va de 2700 a 6300, mientras el largo de la aleta se mide en milímetros y va de 172 a 231: la varianza de la primera es varios órdenes de magnitud mayor.

El resultado es que la primera componente —la flecha naranja— queda prácticamente alineada con el eje de la masa. No descubrió ninguna estructura de los datos: descubrió qué variable se midió con la unidad más chica.

A la derecha las dos variables fueron llevadas a media cero y desvío uno, con lo que compiten en igualdad de condiciones. Recién ahí la primera componente sigue la dirección real de la nube, que es la correlación entre ambas. La regla práctica es simple: si las variables no comparten unidad, estandarizar no es opcional.

1. **Estandarización de los Datos:** Como se mencionó, los datos de entrada se estandarizan para que cada atributo tenga una media de 0 y una desviación estándar de 1.
2. **Cálculo de la Matriz de Covarianza:** PCA construye una matriz de covarianza para medir cómo varían conjuntamente cada par de dimensiones. Esta matriz cuantifica las interrelaciones lineales entre todos los pares de atributos. El objetivo de PCA es encontrar una nueva base donde la matriz de covarianza sea diagonal, eliminando la correlación entre las nuevas variables.
3. **Cálculo de Eigenvectores y Eigenvalues:** A partir de la matriz de covarianza, se calculan sus eigenvectores y eigenvalues.
 - **Eigenvectores:** Representan las **direcciones** de los nuevos ejes, es decir, los **componentes principales**. Son vectores ortogonales que definen la nueva base del espacio de datos.
 - **Eigenvalues:** Indican la **cantidad de varianza** de los datos que es capturada a lo largo de cada eigenvector correspondiente. Un eigenvalue grande significa que su eigenvector asociado explica una gran parte de la varianza total de los datos.

Los componentes principales son, por tanto, los eigenvectores de la matriz de covarianza, ordenados de mayor a menor según su eigenvalue asociado.

Interpretación de Resultados y Aplicación en Visualización Una vez aplicado PCA, la interpretación se centra en cuánta información se ha conservado.

- **Varianza Explicada** (`explained_variance_ratio_`): Es el porcentaje de la varianza total del conjunto de datos original que es capturado por cada componente principal.
- **Varianza Acumulada:** Es la suma de la varianza explicada por los primeros k componentes. El objetivo es retener un alto porcentaje de la varianza (ej. 90% o 95%) con el menor número posible de componentes.

Para fines de visualización, a menudo se toman los **primeros dos componentes principales** y se grafica cada instancia según sus coordenadas en estos dos nuevos ejes. Esto produce una **proyección bidimensional de los datos originales**,

ideal para visualizar estructuras como clústeres o tendencias que eran invisibles en el espacio de alta dimensión.

Es importante mencionar que el resultado de PCA son *variables nuevas abstractas*: combinaciones lineales que a veces carecen de una interpretación simple y directa. Aun así, como herramienta descriptiva y de preprocesamiento, es sumamente potente.

La fig. 14 muestra el resultado sobre el conjunto de pingüinos: a la izquierda la proyección sobre las dos primeras componentes, a la derecha el criterio para decidir cuántas conservar.

Snippet (Python): PCA + scatter 2D y varianza explicada

```

1  import matplotlib.pyplot as plt
2  import seaborn as sns
3  from sklearn.decomposition import PCA
4  from sklearn.preprocessing import StandardScaler
5
6  pinguinos = sns.load_dataset("penguins").dropna()
7  num_cols = ["bill_length_mm", "bill_depth_mm", "flipper_length_mm", "body_mass_g"]
8
9  # PCA exige estandarizar: las cuatro variables estan en unidades distintas.
10 Xz = StandardScaler().fit_transform(pinguinos[num_cols])
11
12 pca = PCA().fit(Xz)
13 proyeccion = pca.transform(Xz)
14 var = pca.explained_variance_ratio_
15
16 # Proyeccion sobre las dos primeras componentes, coloreada por especie
17 for especie in pinguinos["species"].unique():
18     sel = (pinguinos["species"] == especie).to_numpy()
19     plt.scatter(proyeccion[sel, 0], proyeccion[sel, 1], alpha=0.7, label=especie)
20 plt.xlabel(f"PC1 ({var[0]:.1%} de la varianza)")
21 plt.ylabel(f"PC2 ({var[1]:.1%} de la varianza)")
22 plt.legend(title="Especie")
23 plt.show()
24
25 # Varianza explicada acumulada
26 plt.plot(range(1, len(var) + 1), var.cumsum(), marker="o", linestyle="--")
27 plt.axhline(0.95, color="black", linestyle=":")
28 plt.xlabel("Numero de componentes")
29 plt.ylabel("Proporcion acumulada de varianza")
30 plt.xticks(range(1, len(var) + 1))
31 plt.show()

```

Métodos No Lineales de Reducción de Dimensionalidad

Además de PCA (lineal), existen **métodos no lineales** conocidos como técnicas de *manifold learning*, como **t-SNE (t-Distributed Stochastic Neighbor Embedding)** y **UMAP**. Estos métodos intentan preservar relaciones de vecindad o estructuras no lineales al mapear datos de espacios muy dimensionales a 2D o 3D.

Son especialmente útiles para **visualización**, ya que pueden capturar relaciones complejas que PCA podría pasar por alto. t-SNE, por ejemplo, es famoso por proyectar datos de alta dimensión de manera que grupos similares formen conglomerados visuales muy claros. Su objetivo es que puntos cercanos en el espacio original permanezcan cercanos en la proyección de baja dimensión.

Sin embargo, estos métodos tienen contrapartidas: suelen ser computacionalmente más costosos y sus resultados son aún menos interpretables que los de PCA. Las distancias entre clústeres en un gráfico t-SNE no necesariamente tienen un significado cuantitativo, y los ejes no corresponden a combinaciones lineales de las variables originales.

La fig. 15 compara los tres métodos sobre el mismo conjunto de dígitos manuscritos.




Figura 14: El resultado de un análisis de componentes principales se lee en dos figuras complementarias. A la izquierda, las cuatro variables originales quedaron proyectadas sobre las dos primeras componentes, un plano que retiene la mayor parte de la varianza total. Las tres especies aparecen razonablemente separadas pese a que el método es *no supervisado*: nunca vio la etiqueta de especie. Esa separación es la evidencia de que las medidas morfológicas contienen, por sí solas, la información que distingue a las especies.

A la derecha está el criterio para decidir cuántas componentes conservar. Las barras dan el aporte individual de cada una y la curva su acumulado; la línea punteada marca el umbral convencional del 95 %. El punto donde la curva cruza esa línea indica cuántas dimensiones alcanzan para no perder prácticamente nada, y el codo de la curva señala dónde empieza a haber rendimientos decrecientes.

Snippet (Python): t-SNE para visualización

```
1 import matplotlib.pyplot as plt
2 import seaborn as sns
3 from sklearn.manifold import TSNE
4 from sklearn.preprocessing import StandardScaler
5
6 pinguinos = sns.load_dataset("penguins").dropna()
7 num_cols = ["bill_length_mm", "bill_depth_mm", "flipper_length_mm", "body_mass_g"]
8 Xz = StandardScaler().fit_transform(pinguinos[num_cols])
9
10 # perplexity controla cuantos vecinos considera cada punto; max_iter reemplaza al
11 # antiguo n_iter, retirado en scikit-learn 1.5.
12 tsne = TSNE(n_components=2, random_state=42, init="pca",
13             perplexity=30, max_iter=1000)
14 emb = tsne.fit_transform(Xz)
15
16 for especie in pinguinos["species"].unique():
17     sel = (pinguinos["species"] == especie).to_numpy()
18     plt.scatter(emb[sel, 0], emb[sel, 1], alpha=0.7, label=especie)
19 plt.title("Proyeccion t-SNE")
20 plt.legend(title="Especie")
21 plt.xticks([]); plt.yticks([])
22 plt.show()
```

Selección de Atributos: Un Enfoque Alternativo

Por último, es relevante mencionar la **selección de atributos (feature selection)** como otra forma de reducción dimensional. A diferencia de PCA, que crea *nuevas* variables combinadas, este enfoque simplemente elige un subconjunto de las variables originales, eliminando aquellas irrelevantes o redundantes. Herramientas como la **matriz de correlaciones**




Figura 15: Tres proyecciones del mismo conjunto de 64 dimensiones a 2, coloreadas por la clase verdadera. PCA busca las direcciones de máxima varianza y solo puede aplicar una transformación lineal; el resultado conserva la geometría global —las distancias grandes siguen siendo grandes— pero deja los diez dígitos parcialmente superpuestos.

t-SNE y UMAP abandonan esa restricción y optimizan la preservación de la estructura *local*: lo que intentan es que los puntos que eran vecinos en el espacio original sigan siendo vecinos en el plano. El resultado separa los grupos con mucha más nitidez, y por eso son las técnicas de referencia para inspeccionar visualmente si un conjunto tiene estructura de clases.

El precio hay que tenerlo presente al interpretar: en t-SNE y UMAP **las distancias entre grupos no son cuantitativamente interpretables**. Que dos cúmulos aparezcan lejos no significa que sean más distintos que dos que aparecen cerca, y el tamaño de cada cúmulo tampoco refleja la dispersión real. Son mapas de vecindad, no de magnitud.

pueden ayudar a detectar variables muy correlacionadas, donde quizás solo una de ellas sea necesaria, preservando así la interpretabilidad original de las características.

Conclusión

La reducción de dimensionalidad, mediante técnicas como PCA o embeddings no lineales, tiene **aplicaciones directas y poderosas en la visualización exploratoria** de datos complejos. Permite crear gráficos en 2D o 3D que condensan información de decenas o cientos de dimensiones, haciendo posible descubrir estructuras globales como clústeres, tendencias y casos atípicos multivariados. Un analista de datos puede usar estas visualizaciones para guiar las siguientes etapas del proyecto. Además, al condensar la información, estas técnicas sirven como un paso de preprocesamiento crucial para muchos algoritmos de machine learning, mejorando su eficiencia y, a veces, su rendimiento. No obstante, es vital entender que siempre existe una pérdida de información al reducir dimensiones. El analista debe evaluar cuánta varianza o estructura está dispuesto a sacrificar a cambio de simplicidad y visualización.

En síntesis, en este capítulo hemos abarcado los fundamentos del análisis exploratorio de datos en proyectos de inteligencia artificial: desde el rol crucial del EDA y la estadística descriptiva para comprender y resumir datos, pasando por análisis univariados, bivariados y multivariados con sus respectivas técnicas (tablas, correlaciones, gráficos) hasta estrategias prácticas para grandes dimensiones y volúmenes (muestreo y reducción dimensional). Estas herramientas teóricas constituyen la base para abordar con éxito conjuntos de datos complejos antes de adentrarse en modelados predictivos o algoritmos de aprendizaje, garantizando así que las decisiones y conclusiones posteriores estén sustentadas en un conocimiento sólido de la naturaleza de los datos.

Bibliografía

Hair, J.F., Black, W.C., Babin, B.J. & Anderson, R.E. (2019). *Multivariate Data Analysis*. 8va edición. Cengage.

Han, J., Pei, J. & Tong, H. (2022). *Data Mining: Concepts and Techniques*. 4ta edición. Morgan Kaufmann.

Kuhn, M. & Johnson, K. (2020). *Feature Engineering and Selection: A Practical Approach for Predictive Models*. CRC Press.

McKinney, W. (2022). *Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter*. 3ra edición. O'Reilly Media.

Nussbaumer Knaflic, C. (2015). *Storytelling with Data: A Data Visualization Guide for Business Professionals*. Wiley.

Zheng, A. & Casari, A. (2018). *Feature Engineering for Machine Learning: Principles and Techniques for Data Scientists*. O'Reilly Media.