

Capítulo 2: Análisis Exploratorio de Datos y Visualización

Introducción

Basado en Knafllic (2015); Han, Pei y Tong (2022)

Es importante distinguir el **análisis exploratorio** del análisis **expositivo** o explicativo. Durante la exploración, el objetivo es entender los datos y generar posibles hipótesis; en cambio, en la fase explicativa (por ejemplo al preparar un reporte o presentación) el objetivo es **comunicar una historia específica** basada en hallazgos ya identificados. Una buena visualización narrativa debe enfocarse en esas “perlas” –los patrones o insights clave– y no abrumar a la audiencia con todos los detalles brutos de la exploración. Como señala Knafllic (2015), tras analizar nuestros datos es tentador querer mostrar absolutamente *todo* el análisis realizado, pero esto suele ser contraproducente: el público no necesita (ni desea) revisar cada paso exploratorio, sino comprender los hallazgos más importantes. Por lo tanto, debemos filtrar y dar contexto a los resultados, entrando así al terreno de la **narrativa con datos** o *data storytelling*.

En este capítulo introduciremos los principios de **diseño visual y narrativa** en la comunicación de datos, las estrategias para una **exploración de datos eficiente** (especialmente en conjuntos de datos grandes), y las técnicas de **visualización de resultados de modelos** (regresión, clasificación, clustering) de forma narrativa. Además, veremos ejemplos de **aplicaciones** de estas técnicas en distintos dominios, y discutiremos cómo la visualización se integra en **reportes automatizados y tableros** para respaldar la toma de decisiones basada en evidencia. A lo largo del texto se incorporarán fragmentos de código en Python (usando bibliotecas como pandas, Matplotlib, Seaborn, etc.) para ilustrar la implementación práctica de algunas ideas, así como gráficos originales inspirados en los libros de referencia de la cátedra.

Principios de diseño y narrativa visual para comunicar patrones, tendencias y anomalías

Basado en Knafllic (2015)

El **diseño efectivo de visualizaciones** y la construcción de una **narrativa visual** clara son cruciales para comunicar los hallazgos de datos de forma comprensible y persuasiva. Una visualización bien diseñada puede revelar rápidamente patrones de comportamiento, tendencias temporales o valores atípicos que de otro modo pasarían inadvertidos en tablas de números. A continuación, resumimos los principios fundamentales de diseño y narrativa visual, basándonos principalmente en las lecciones de Cole Nussbaumer Knafllic (2015):

Una comunicación efectiva de hallazgos **no consiste solo en mostrar datos**, sino en contar una historia convincente con ellos. Para ello es necesario aplicar **principios de diseño visual** y construir una **narrativa** que permita a la audiencia comprender patrones, tendencias y anomalías en los datos de forma clara. Nussbaumer Knafllic (2015) propone seis lecciones fundamentales para lograr este objetivo, que sirven como guía para transformar descubrimientos del análisis exploratorio en mensajes impactantes.




Figura 1: Ejemplo de storyboard manuscrito utilizado para planificar la narrativa de una presentación de datos. Antes de elaborar gráficos finales, es útil bosquejar en papel la historia que queremos contar, definiendo el flujo de información y el mensaje central para la audiencia. (Knafllic, 2015).

Aplicar estas seis lecciones garantiza que al comunicar patrones, tendencias o anomalías identificados en el análisis exploratorio, lo hagamos de forma intencionada y efectiva. Al **entender el contexto** y elegir la **visualización adecuada**, eliminando **distracciones** y **enfocando la atención** con intención de **diseño**, conseguiremos contar una historia respaldada por los datos que resuene en nuestra audiencia. Estas habilidades de narrativa visual no dependen de herramientas específicas, sino de fundamentos que trascienden el software: como enfatiza Knaflíc, los principios aprendidos son aplicables en cualquier herramienta de gráficos o presentaciones. En suma, un buen análisis exploratorio culmina con una buena historia respaldada por visualizaciones bien diseñadas.

Las Seis Lecciones Clave para Dominar la Narración de Historias con Datos

1. Comprender el Contexto

Esta lección enfatiza que el punto de partida de la visualización de datos es la **comprensión profunda del contexto** de la comunicación. Antes de visualizar cualquier dato, es fundamental tener claridad sobre **quién, qué y cómo** se va a comunicar.

- **Quién (Su Audiencia):** Es esencial ser lo más específico posible sobre la audiencia. Evitar “audiencias generales” permite una comunicación más efectiva. Se debe considerar la relación con la audiencia y si ya existe confianza.
- **Qué (Acción):** Se debe definir claramente **qué se quiere que la audiencia sepa o haga**. El comunicador, como experto en la materia, debe interpretar los datos y **guiar a la audiencia hacia la comprensión y la acción**, incluso si esto implica salir de la zona de confort. No basta con presentar datos; se debe pedir una acción clara.
- **Cómo (Mecanismo y Tono)** (fig. 2): El método de comunicación impacta el control sobre cómo la audiencia consume la información y el nivel de detalle necesario.
- Una **presentación en vivo** permite al presentador controlar la atención de la audiencia, requiriendo diapositivas más concisas y una buena preparación.
- Un **documento escrito** o correo electrónico otorga menos control al creador, por lo que exige mayor detalle explícito y autoexplicación.
- El término “**slideument**” se refiere a documentos que intentan satisfacer ambas necesidades, lo cual presenta desafíos.
- El **tono** deseado (celebratorio, urgente, serio) también influye en las decisiones de diseño.




Figura 2: Espectro de mecanismos de comunicación. En el extremo izquierdo, con una presentación en vivo, vos (la persona que presenta) estás en control total. Determinás qué ve la audiencia y cuándo lo ve. Podés responder a señales visuales para acelerar, desacelerar o profundizar más o menos en un punto en particular. No hace falta que todo el detalle esté directamente en la comunicación (la presentación o el conjunto de diapositivas), porque vos, como especialista en el tema, estás ahí para responder cualquier pregunta que surja durante la presentación y deberías poder y estar preparado para hacerlo, independientemente de que ese detalle esté o no en la propia presentación. (Knaflíc, 2015).

Para lograr concisión y claridad en el contexto, se recomiendan dos herramientas: * La **historia de 3 minutos**: Comunicar lo esencial en tres minutos para asegurar que se tiene claridad sobre el mensaje principal. * La **Gran Idea**: Resumir el “qué sigue” o el punto de vista principal en una sola oración, articulando lo que está en juego y siendo una oración completa.

Finalmente, el **storyboarding** (fig. 1) es una herramienta crucial para estructurar la comunicación visualmente, recomendando empezar con herramientas de baja tecnología (pizarras, Post-it notes) para evitar el apego prematuro al trabajo digital.

2. Elegir una Visualización Efectiva

Este capítulo se enfoca en seleccionar la mejor manera de presentar los datos, destacando que un puñado de tipos de visualizaciones satisfacen la mayoría de las necesidades. Los gráficos interactúan con nuestro sistema visual, lo que permite un procesamiento más rápido de la información que las tablas.

- **Texto Simple:** Ideal cuando solo se tienen uno o dos números que comunicar, permitiendo que destaquen con “fuerza”.
- **Tablas:** Interactúan con nuestro sistema verbal (las leemos) y son excelentes para audiencias mixtas que buscan filas específicas o para comunicar múltiples unidades de medida. Sin embargo, **raramente son una buena idea en presentaciones en vivo** porque la audiencia leerá en lugar de escuchar. El diseño de la tabla debe “desvanecerse” para que los datos sean el foco, utilizando bordes ligeros o espacio en blanco.
- **Mapas de Calor (Heatmaps):** Visualizan datos tabulares usando celdas coloreadas para transmitir la magnitud relativa de los números, lo que ayuda a identificar rápidamente los puntos de interés.
- **Gráficos de Puntos (Scatterplots):** Útiles para mostrar la relación entre dos cosas, codificando datos en ejes X e Y.
- **Gráficos de Líneas:** Comúnmente usados para graficar **datos continuos**, a menudo en unidades de tiempo. Incluyen gráficos de líneas estándar y **gráficos de pendiente (slopegraphs)**, que son útiles para comparar dos periodos de tiempo o puntos de comparación, mostrando rápidamente aumentos y disminuciones relativas.
- **Gráficos de Barras:** Son el tipo de gráfico preferido por la autora para datos categóricos debido a su facilidad de lectura. Los ojos comparan los puntos finales de las barras, facilitando la visualización de las diferencias. Es **crucial que los gráficos de barras siempre tengan una línea base cero** para evitar comparaciones visuales falsas. Incluyen barras verticales, barras apiladas verticales (con usos más limitados para comparar subcomponentes), gráficos de cascada para mostrar la composición de cambios, y **barras horizontales** (preferidas para nombres de categorías largos). El orden lógico de las categorías es importante. La fig. 3 reúne los doce tipos que cubren la mayoría de las necesidades, y la fig. 4 contrasta dos formas desaconsejadas con su reemplazo.
- **Gráficos de Área:** La autora los evita en su mayoría porque los ojos humanos no son buenos atribuyendo valor cuantitativo al espacio bidimensional, con la excepción del gráfico de área cuadrada para magnitudes muy diferentes.

Visualizaciones a evitar: * **Gráficos de pastel (pie charts):** Considerados “malvados,” son difíciles de interpretar con precisión debido a la dificultad de comparar ángulos y áreas. * **Gráficos de donut:** También difíciles de interpretar ya que requieren comparar longitudes de arco. * **Gráficos 3D:** La regla de oro es “**Nunca uses 3D**” a menos que se grafique una tercera dimensión real, ya que distorsionan los números y añaden elementos innecesarios. * **Ejes Y secundarios:** Generalmente no son una buena idea porque requieren tiempo para entender qué datos se relacionan con qué eje, confundiendo la interpretación.

3. Eliminar el Desorden

Este capítulo enfatiza la importancia de **eliminar el desorden** en las comunicaciones visuales (fig. 5), ya que cada elemento en una página o pantalla consume “carga cognitiva” por parte de la audiencia.

- **Carga Cognitiva:** Se refiere al esfuerzo mental requerido para aprender nueva información. El **desorden visual** crea una **carga cognitiva excesiva o extraña**, lo que significa que el cerebro de la audiencia trabaja sin entender la información. Esto hace que los visuales parezcan más complicados de lo necesario y puede llevar a que la audiencia desista de intentar comprender el mensaje.
- **Principios de la Gestalt de la Percepción Visual:** Ayudan a identificar el desorden y cómo las personas perciben el orden en el mundo.
- **Proximidad:** Objetos cercanos se perciben como parte de un grupo.
- **Similitud:** Objetos con características similares (color, forma, tamaño) se perciben como relacionados.

Los doce tipos de gráfico que cubren la mayoría de las necesidades



Figura 3: El repertorio completo es más chico de lo que parece. Estos doce tipos cubren prácticamente todas las necesidades de comunicación de datos, y la elección entre ellos no es estética sino funcional: depende de qué tenga que hacer el lector con la información.

Cuando hay uno o dos números y lo que importa es que impacten, el texto simple es más efectivo que cualquier gráfico. Cuando el lector va a buscar valores puntuales, conviene una tabla. Para comparar magnitudes entre categorías, barras; si las etiquetas son largas, horizontales. Para seguir una evolución en el tiempo, líneas; para comparar solo dos momentos entre varias series, un slopegraph. Para descomponer una variación en sus aportes, una cascada.

El criterio de fondo es que el gráfico aproveche el sistema visual: la posición sobre un eje común es lo que el ojo compara con mayor precisión, y por eso barras y líneas resuelven bien la mayoría de los casos.




Figura 4: Dos recursos muy difundidos que conviene descartar, con la alternativa al lado.

El gráfico de torta pide comparar ángulos y áreas, que es justamente lo que el sistema visual hace peor. Frente a los mismos cuatro valores, decidir cuál porción es mayor exige esfuerzo y admite error; las barras horizontales convierten esa comparación en una lectura de longitudes sobre un eje común, que es la tarea perceptual más precisa que existe. Por eso el problema se agrava cuando hay más de tres categorías o cuando los valores son parecidos.

Las barras en tres dimensiones agregan una dimensión que no codifica ningún dato. La perspectiva deforma las alturas —las barras del fondo se ven más chicas de lo que son— y las caras superiores hacen ambiguo dónde termina cada valor. Es decoración que compite con la información. La versión plana dice exactamente lo mismo sin distorsión.

La regla general que ordena los dos casos: todo elemento que no aporta información compite con la que sí aporta.




Figura 5: La eliminación del desorden reduce la carga cognitiva y mejora la accesibilidad del visual. (Knaflitz, 2015).

- **Cerramiento (Enclosure):** Objetos físicamente encerrados se perciben como parte de un grupo.
- **Cierre (Closure):** Las personas tienden a percibir un conjunto de elementos como una forma completa, permitiendo eliminar elementos como bordes de gráficos o sombreados de fondo.
- **Continuidad:** Los ojos buscan el camino más suave, creando continuidad (ej., eliminando líneas de eje Y).
- **Conexión:** Objetos conectados físicamente se perciben como parte de un grupo con un fuerte valor asociativo.
- **Falta de Orden Visual:** Un diseño bien pensado se “desvanece” en el fondo. La **alineación** (ej., texto justificado a la izquierda) es clave para crear líneas limpias y un diseño ordenado, evitando elementos diagonales que son difíciles de leer. El **espacio en blanco** es crucial para enfatizar y crear pausas visuales.
- **Uso no estratégico del contraste:** Si demasiadas cosas son diferentes, ninguna sobresale. Se debe usar el contraste estratégicamente para que lo importante se destaque.

4. Enfocar la Atención de la Audiencia

Este capítulo explora cómo las personas ven y procesan la información para **enfocar la atención de la audiencia** (fig. 6).




Figura 6: Las marcas añadidas funcionan como una señal de «mirá acá», atrayendo la atención de la audiencia más rápidamente hacia el lado derecho del gráfico. (Knaflitz, 2015).

- **Usted ve con su cerebro:** La visión implica un procesamiento significativo en el cerebro, no solo en los ojos. Se distinguen tres tipos de memoria relevantes para el diseño visual:
- **Memoria Icónica:** Súper rápida, inconsciente, sintonizada con los **atributos preatentivos**. Es un mecanismo de supervivencia que permite detectar rápidamente diferencias.
- **Memoria a Corto Plazo:** Limitada a unos cuatro “fragmentos” de información visual a la vez. El exceso de información sobrecarga esta memoria.
- **Memoria a Largo Plazo:** Construida a lo largo de la vida, vital para el reconocimiento de patrones. Las imágenes pueden ayudar a recordar información almacenada en la memoria verbal a largo plazo.
- **Los atributos preatentivos** (fig. 7) son herramientas poderosas que permiten que la audiencia vea lo que se quiere que vean incluso antes de que sepan que lo están viendo. Incluyen **movimiento, posición espacial, intensidad, tonalidad (hue), ancho y longitud de línea, forma, orientación, cerramiento, marcas añadidas, curvatura y tamaño**.
- Usados con moderación, son útiles para **dirigir la atención rápidamente** y **crear una jerarquía visual de información**.
- **Tamaño:** Denota importancia; los elementos importantes deben ser grandes.
- **Color:** Una de las herramientas más poderosas cuando se usa con moderación, siempre debe ser una **decisión intencional**.
- Usar con moderación (demasiada variedad diluye su valor).
- Usar de forma consistente (la historia debe mantener la atención, no los colores; los cambios de color deben señalar cambios de tema o tono).
- Diseñar pensando en los daltónicos (evitar rojo/verde juntos, usar señales visuales adicionales).
- Considerar el tono que transmite el color (evoca emociones).
- Integrar colores de marca, pero asegurar que resalten.
- **Posición en la página:** La parte superior izquierda es un “bien inmueble precioso”; colocar lo más importante allí.

5. Pensar como un Diseñador

La fig. 8 recorre el efecto acumulado de aplicar estos criterios sobre una misma visualización. Este capítulo aplica conceptos de diseño tradicional a la comunicación de datos, enfatizando la máxima “**La forma sigue a la función**”. El diseño debe permitir que la audiencia interactúe con los datos con facilidad.




Figura 7: Los atributos preatentivos son las propiedades visuales que el cerebro procesa antes de la atención consciente, en menos de 250 milisegundos. En cada panel hay cuarenta y cinco elementos y uno solo difiere; ubicarlo no requiere recorrer la grilla, porque el elemento distinto se impone.

La consecuencia para el diseño de un gráfico es directa: estos atributos son el mecanismo con el que se dirige la mirada del lector hacia lo que importa. Un solo dato en color mientras el resto queda en gris, un rótulo de mayor tamaño, una marca añadida sobre el punto que sostiene el argumento.

El costo de usarlos mal también es directo. Cada atributo que se emplea sin codificar información gasta un recurso de atención finito, y varios compitiendo entre sí se anulan: si todo está resaltado, nada lo está.

- **Affordances (Sugerencias de Uso):** Aspectos del diseño que hacen obvio cómo usar un producto. En visualización de datos, se trata de usar señales visuales para indicar cómo interactuar.
- **Resaltar lo importante:** Usar atributos preatentivos para dirigir la atención, pero solo resaltar una fracción (máximo 10%) del total para no diluir el efecto. Técnicas incluyen negrita, cursiva, subrayado, MAYÚSCULAS, color, inversión de elementos y tamaño.
- **Eliminar distracciones:** Inspirado en la frase de Antoine de Saint-Exupéry, “La perfección se logra... cuando no hay nada más que quitar”. Implica eliminar datos no críticos, resumir cuando no se necesita detalle y relegar elementos necesarios pero no esenciales al fondo (ej., con color gris claro).
- **Crear una jerarquía visual clara de la información:** Utilizar los mismos atributos preatentivos para guiar a la audiencia sobre el orden en que deben procesar la información, empujando algunos elementos al frente y otros al fondo.
- **Accesibilidad:** Diseños utilizables por personas con diversas habilidades, incluyendo habilidades técnicas.
- **No sobrecomplicar:** Un diseño que parece complicado disuade a la audiencia. Esto implica usar una **fente legible y consistente**, mantener el diseño limpio, usar un **lenguaje sencillo** y **eliminar la complejidad innecesaria**.
- **El texto es tu amigo:** El texto es fundamental para etiquetar, introducir, explicar, reforzar, resaltar, recomendar y contar una historia. Cada gráfico necesita un título y cada eje debe tener un título. Los **títulos de acción** en las diapositivas son “bien inmueble precioso” para comunicar la idea principal. La **anotación directa** en el gráfico es útil.
- **Estética:** Hacer los diseños “bonitos” es necesario porque los diseños más estéticos se perciben como más fáciles de usar, se aceptan mejor y fomentan el pensamiento creativo. Se enfatiza el uso inteligente del color, la atención a la alineación y el aprovechamiento del espacio en blanco para lograr un diseño estético y organizado.
- **Aceptación:** Un diseño debe ser aceptado por su audiencia. Se ofrecen estrategias como articular los **beneficios**, mostrar el “**lado a lado**” (antes y después), proporcionar **múltiples opciones**, involucrar a un **miembro influyente** y buscar comentarios imparciales.




Figura 8: Al resaltar lo importante y eliminar las distracciones, hemos mejorado notablemente esta visualización. (Knaflíc, 2015).

6. Contar una Historia

Este capítulo explora el poder de la narración de historias para comunicar eficazmente con datos, comparándola con el cuento de Caperucita Roja para ilustrar la **fuerza de la repetición** y la **estructura de principio, nudo y desenlace**. Las historias capturan la atención, evocan una respuesta emocional y son fáciles de recordar.

- **Lecciones de Narradores Maestros:**
- **Aristóteles (teatro):** Estructura de tres actos: **planteamiento** (presentación de personajes, entorno, incidente), **conflicto** (desarrollo del problema) y **resolución** (clímax, respuesta a la pregunta dramática). El conflicto y la tensión son integrales.
- **Robert McKee (cine):** La persuasión a través de la historia une una idea con una emoción, a diferencia de la retórica convencional (hechos y estadísticas) que solo persuade intelectualmente. Las historias revelan cómo y por qué cambia la vida, partiendo de un equilibrio que se rompe, lo que crea lucha, conflicto y suspenso.
- **Kurt Vonnegut (palabra escrita):** Consejos clave incluyen: encontrar un tema que importe, no divagar, **mantenerlo simple**, **tener el valor de cortar** (eliminar lo que no ilumine el tema), sonar como uno mismo, decir lo que se quiere decir y, lo más importante, **apiadarse de los lectores** (simplificar y clarificar). La comunicación debe ser para la

audiencia.

- **Construyendo la Historia:** Debe tener un **principio, nudo y desenlace**.
- **El Principio:** Introduce el **planteamiento** (escenario, personaje principal, estado sin resolver, resultado deseado y solución). El “personaje principal” debe ser la audiencia, enmarcando la historia en términos de su problema.
- **El Nudo:** Desarrolla el “lo que podría ser”, convenciendo a la audiencia de la necesidad de acción. Puede incluir antecedentes, contexto, ejemplos, datos que demuestren el problema, consecuencias de no actuar y beneficios de la solución propuesta. Debe ser relevante para la audiencia y sus motivaciones.
- **El Final:** Termina con una **clara llamada a la acción**, reiterando la urgencia y el nuevo entendimiento.
- **La Estructura Narrativa:** Son las palabras que cuentan la historia de manera que tenga sentido y convenza a la audiencia. Un buen visual puede fallar sin una narrativa convincente.
- **Flujo Narrativo:** Determinar el orden en que la audiencia experimentará la historia. Puede ser **cronológico** (siguiendo el proceso analítico) o **empezar por el final** (con la llamada a la acción). El concepto “Bing, Bang, Bongo” (fig. 9) ayuda a establecer la estructura (decir lo que se va a decir, decirlo, resumirlo).
- **Narrativa Hablada y Escrita:** En una **presentación en vivo**, la voz en off refuerza el mensaje, pero las diapositivas deben ser concisas. En un **informe escrito**, la narrativa debe ser autoexplicativa y clara.
- **El Poder de la Repetición:** Repetir información importante ayuda a transferirla a la memoria a largo plazo. El concepto “Bing, Bang, Bongo” es clave para esto.




Figura 9: Bing, bang, bongo. (Knafllic, 2015).

- **Tácticas para asegurar la Claridad de la Historia:**
- **Lógica Horizontal:** Leer solo los títulos de las diapositivas (títulos de acción) debe contar la historia principal.
- **Lógica Vertical:** Toda la información en una diapositiva debe ser autorreforzante; el contenido refuerza el título y viceversa.
- **Storyboarding Inverso:** Revisar la comunicación final y anotar el punto principal de cada página para ver si cuenta la historia deseada.
- **Una Perspectiva Fresca:** Obtener comentarios de amigos o colegas imparciales para ver si la comunicación logra su objetivo.

El **personaje principal de cada historia siempre debe ser la audiencia**, haciendo que los datos sean relevantes para ellos y transformando la simple “muestra de datos” en una “narración de historias con datos”.

Al aplicar estas lecciones, se pueden impulsar mejores decisiones e incitar a la acción, en lugar de simplemente mostrar datos.

La visualización como parte de los reportes automáticos y tableros para una comunicación basada en evidencias

Basado en Knafllic (2015); McKinney (2022)

En la práctica profesional actual, los análisis de datos no terminan en un informe estático, sino que a menudo se integran en **sistemas de reporte automático y tableros de control (dashboards)** que se actualizan periódicamente con datos nuevos. La visualización desempeña un rol central en estos sistemas, ya que es el medio por el cual los usuarios finales –gerentes, clientes, ciudadanía, etc.– **consumen la información de manera rápida y comprensible**. Una comunicación verdaderamente basada en evidencias implica que las conclusiones y decisiones están respaldadas por datos accesibles visualmente en cualquier momento, no escondidos en documentos técnicos. Veamos cómo se enlazan las visualizaciones

con reportes automatizados y tableros, y qué consideraciones de diseño emergen en este contexto.

1. Reportes automatizados reproducibles: Herramientas como Jupyter Notebooks (Python) o R Markdown han revolucionado la forma de generar informes. Permiten combinar en un mismo documento el código de análisis, la descripción en lenguaje natural y las visualizaciones resultantes, de tal forma que el reporte pueda ser **re-ejecutado automáticamente con nuevos datos** para actualizar las cifras y gráficos. Wes McKinney (2022) destaca la importancia de usar notebooks y scripts bien organizados para mantener la reproducibilidad del análisis. Por ejemplo, imaginemos un reporte mensual de ventas: en lugar de preparar manualmente gráficas y tablas cada mes, se puede tener un notebook que al cambiar la fecha carga los datos actualizados y regenera todas las visualizaciones (gráficos de barras de ventas por región, curvas de tendencia, etc.). Esto ahorra tiempo y elimina errores humanos, a la vez que asegura coherencia (la lógica es la misma cada mes).

Desde el punto de vista de la comunicación, el hecho de automatizar no quita la necesidad de buen diseño; de hecho, se vuelve más crítico porque esos gráficos se producirán recurrentemente. Knaflíc (2015) sugiere **estandarizar plantillas visuales** de modo que la audiencia se familiarice con el formato y pueda concentrarse en el contenido. Por ejemplo, si todos los meses se presenta un gráfico de KPI con un objetivo marcado por una línea punteada roja, el lector sabrá inmediatamente buscar la posición de la barra respecto a esa línea para ver si se cumplió la meta. Una estructura consistente (mismos colores para mismas categorías, mismos tipos de gráficos para indicadores similares) crea un lenguaje visual corporativo que facilita la lectura rápida de reportes automatizados.

Otro aspecto es que los reportes reproducibles permiten **ahondar en detalles bajo demanda**. Por ejemplo, un notebook puede ocultar el código fuente pero permitir al lector técnico revelarlo si le interesa verificar cómo se calculó cierta cifra – esto aporta transparencia. Asimismo, se pueden incluir visualizaciones interactivas básicas (como toggles para cambiar de vista) que, aunque en un PDF impreso no funcionen, en formato HTML o en una plataforma de notebooks compartidos (Google Colab, Jupyter NBViewer) permiten al usuario explorar un poco más allá de lo predefinido.

2. Dashboards y visualizaciones interactivas: Los tableros de control son entornos visuales donde múltiples gráficos e indicadores se muestran simultáneamente, a menudo con capacidad de filtrado y segmentación interactiva por parte del usuario. La visualización aquí es el componente fundamental: cada *widget* del dashboard –sea un gráfico de líneas, un medidor, un mapa, etc.– comunica una métrica o parte de la historia de los datos. La clave es lograr un **diseño cohesivo y centrado en la evidencia**: cada gráfico debe aportar a la narración general del estado del sistema o negocio, evitando visualizaciones de “adorno” que no guíen a una acción o insight.

Un dashboard bien diseñado para comunicación basada en evidencia podría ser, por ejemplo, el tablero de control de COVID-19 que utilizan los responsables de salud pública. En una sola pantalla, puede haber:

- Un **mapa** del país coloreado por tasa de casos por 100 mil habitantes (evidencia geográfica de focos).
- Un **gráfico de líneas** de la evolución de casos diarios a nivel nacional (tendencia temporal).
- Un **indicador numérico** grande de % de población vacunada, quizás con un ícono verde si supera cierto umbral (metas).
- Un **gráfico de barras** comparativo de número de tests vs positivos por semana (indicador de suficiencia de tests).
- Opciones de filtro por provincia o por rango de fechas.

Toda esta visualización integrada (fig. 10) permite a los decisores tener una **fotografía completa, actualizada y personalizable** de la situación, para actuar basados en esa evidencia visual. Si ven en el dashboard que en cierta provincia el mapa está en rojo oscuro y la línea de casos sube empinada, esa evidencia respalda medidas de contención en esa provincia.

Para lograr efectividad:

- Se sigue aplicando “*menos es más*”: mostrar los gráficos necesarios y no abrumar con 20 plots en una pantalla. Un principio es la “regla de 5 segundos”: el usuario debe captar la información principal del dashboard en pocos segundos. Eso requiere jerarquía visual (lo más importante más grande o destacado) y eliminar ruido.
- **Interactividad enfocada:** Es tentador dar mil opciones al usuario, pero Knaflíc advierte que demasiadas opciones pueden distraer de la historia principal. Lo ideal es permitir filtrado en lo que es relevante (ej., elegir región o periodo) pero no complicar con configuraciones cosméticas innecesarias.
- **Consistencia:** Como en reportes, usar mismos colores/símbolos para la misma métrica a través de todos los gráficos del dashboard. Si en el mapa la categoría “Alto riesgo” es roja, en la barra o texto también usar rojo para referirse a riesgo, etc. Esto crea un hilo conductor que guía el ojo del usuario por la evidencia relacionada.




Figura 10: Dashboard mundial de COVID-19: integra resumen numérico global, curva temporal de activos/recuperados/muertes, mapa por país (valores absolutos o por millón) y rankings de países por letalidad, recuperación y muertes, con filtros por fecha, región y tipo de caso.

Herramientas interesantes para hacer dashboards

- **Streamlit:** Ideal para crear aplicaciones web con dashboards interactivos de forma rápida y sencilla, utilizando Python.
- **Dash:** Un framework de Python para crear aplicaciones web analíticas. Es muy versátil y potente.
- **Bokeh:** Una biblioteca de visualización interactiva para navegadores web modernos. Permite crear gráficos y dashboards complejos.
- **Power BI:** Una herramienta de inteligencia de negocios de Microsoft que permite crear dashboards y informes interactivos a partir de diversas fuentes de datos.
- **Tableau:** Otra herramienta líder en inteligencia de negocios, conocida por su facilidad de uso y sus potentes capacidades de visualización.
- **Google Data Studio:** Una herramienta gratuita de Google que permite crear informes y dashboards personalizados a partir de datos de Google Analytics, Google Sheets y otras fuentes.
- **Metabase:** Una herramienta de código abierto que permite a los usuarios hacer preguntas sobre sus datos y visualizar las respuestas en forma de gráficos y dashboards.

3. Comunicación en tiempo real y alertas: Algunos tableros están pensados para monitoreo en tiempo real (por ejemplo, sistema de servidores de una empresa). Aquí la visualización puede incluir elementos dinámicos: gráficos que se actualizan automáticamente cada pocos segundos. La narrativa basada en evidencia en este contexto se manifiesta en la **detección visual inmediata de anomalías**. Por ejemplo, un tablero de monitoreo de red puede tener un gráfico de área que muestra el uso de CPU de cada servidor. En condiciones normales están bajos; si de repente una curva de servidor se dispara cerca del 100% y se torna roja (cambio de color programado al pasar cierto umbral), el operador visualmente ve la evidencia de un problema y puede hacer clic para más detalles. Este es un ejemplo donde la *visualización no solo comunica, sino que activa directamente una respuesta*, encarnando la comunicación basada en evidencia de manera operativa.

Asimismo, las **alertas visuales** (luces, íconos) integradas en tableros cumplen la función de sintetizar evidencia compleja en un símbolo fácil de interpretar. Un semáforo rojo al lado de “Calidad de datos” en un dashboard de ETL, por ejemplo, condensa posiblemente muchas estadísticas internas (nullos, validaciones fallidas), pero al usuario final le dice inmediatamente “los datos hoy no están confiables, ten cautela con las conclusiones”. Esa simple visualización

(rojo/amarillo/verde) sustenta la toma de decisiones basada en la calidad de la evidencia.

4. Historias de datos compartidas: Herramientas colaborativas como Google Data Studio, Tableau Public o incluso presentaciones de Slides con gráficos vinculados, permiten difundir narrativas basadas en evidencias a un público amplio. Un ejemplo es el caso de **data journalism**: medios como *The New York Times* o *El País* frecuentemente publican historias donde los gráficos interactivos son protagonistas para que el público explore la evidencia detrás de la noticia (Knaflíc los menciona como buenos ejemplos de infográficos informativos). Por ejemplo, un artículo sobre cambio climático puede incluir un gráfico interactivo donde el lector ve la tendencia de temperatura global y puede pasar el cursor para ver datos de cada año, reforzando la credibilidad de la historia con datos transparentes.

En entornos corporativos, compartir dashboards interactivos en la intranet significa que cualquier área puede “jugar” con los datos (dentro de parámetros preestablecidos), fomentando una cultura de *decisiones guiadas por datos*. Un jefe de ventas regional puede filtrar el dashboard global solo a su región para ver la evidencia pertinente a su área, empoderándolo para tomar acciones localizadas basadas en esa información.

5. Evidencia vs. narrativa: encontrar el balance: Un punto sutil al integrar visualizaciones en reportes y tableros es mantener un equilibrio entre presentar evidencia cruda y construir una narrativa. Por un lado, deseamos que los gráficos muestren datos objetivos (evidencia) de forma transparente; por otro, una *curación excesiva* de la narrativa (mostrando solo gráficos que apoyan cierta tesis) puede sesgar la interpretación. La buena práctica es diseñar dashboards que ofrezcan una **visión completa y equilibrada**. Por ejemplo, en un reporte ejecutivo se incluirán tanto métricas positivas (p.ej. crecimiento de clientes con un flecha verde hacia arriba) como negativas (p.ej. churn aumento, flecha roja hacia abajo). La tentación de esconder lo negativo va en contra de la comunicación basada en evidencia. Un tablero bien considerado quizás pone lo negativo a la vista pero acompañado de contexto o comparativas: “Churn subió al 5% (rojo), pero notemos en el gráfico histórico que sigue debajo del promedio del año pasado” – eso es evidencia contextualizada, no ocultada. Knaflíc aboga por la honestidad y claridad en los gráficos incluso cuando las noticias no son buenas, pues a la larga construyen confianza en la audiencia.

En cuanto al diseño visual, los reportes automatizados y dashboards suelen requerir iteración y feedback de usuarios. Cole N. Knaflíc sugiere “*iterar y buscar feedback*” constantemente – presentar prototipos de las visualizaciones a algunos usuarios finales, observar si entienden el mensaje, y ajustar en consecuencia. Como estos sistemas se usarán repetidamente, la inversión en refinamiento vale la pena. Por ejemplo, si en un dashboard financiero los usuarios confunden el significado de un gráfico de área apilada, podríamos cambiarlo a barras agrupadas más intuitivas. El objetivo final es que, con el tiempo, la audiencia confíe en las visualizaciones como en un panel de auto: un vistazo y comprenden el estado – esa es la *comunicación basada en evidencias fluida*.

Para concluir, integrar visualizaciones en reportes y tableros automáticos trasciende lo meramente técnico; se trata de institucionalizar la cultura de decisiones informadas por datos. Cuando cada reunión directiva inicia mirando un dashboard de KPIs, o cada analista dispone de un informe reproducible donde verificar los últimos números con sus gráficos explicativos, la evidencia se vuelve el idioma común de la organización. Las buenas visualizaciones actúan aquí como **traductores universales** entre los datos complejos y las acciones concretas. Siguiendo las mejores prácticas de diseño y narrativa aprendidas (contexto claro, foco en insights, diseño limpio y consistente), aseguramos que estos sistemas no solo acumulen cifras sino que *cuenten la historia actualizada del negocio o fenómeno*, permitiendo reaccionar con agilidad y certeza. En palabras de Knaflíc, “*good data visualization tells a story*” – y en un dashboard o reporte continuo, esa historia se va escribiendo día a día con la tinta de los datos frescos.

Gestión eficiente del EDA sobre grandes conjuntos de datos

Basado en McKinney (2022); Han, Pei y Tong (2022)

El rápido crecimiento en volumen de los datos presenta desafíos para el análisis exploratorio. No es lo mismo explorar un dataset de 1.000 filas que uno de 100 millones de registros. En este apartado veremos técnicas y recomendaciones para llevar a cabo EDA de forma **eficiente en grandes conjuntos de datos**, aprovechando herramientas y estrategias que nos permitan manejar la escala sin sacrificar profundidad en el análisis.

Técnicas de Muestreo

El análisis de datos se ha vuelto más importante y prevalente que nunca. Recopilar y almacenar grandes conjuntos de datos es sencillo, pero la clave radica en analizarlos para encontrar patrones, tendencias, anomalías y realizar pronósticos.

Las técnicas de muestreo son cruciales en este proceso, ya que permiten trabajar con una representación reducida de los datos originales, manteniendo su integridad y, a menudo, mejorando la eficiencia del análisis posterior. El costo de obtener una muestra es proporcional a su tamaño, no al tamaño total del conjunto de datos, lo que hace que la complejidad del muestreo sea potencialmente sublineal en relación con el volumen de los datos.

Muestreo Aleatorio Simple *Basado en Han, Pei y Tong (2022); Kuhn y Johnson (2020); McKinney (2022)*

- **Concepto:** El muestreo aleatorio simple implica que cada elemento o individuo de la población tiene la **misma probabilidad de ser seleccionado** para formar parte de la muestra. Una estrategia sencilla es la **toma de muestras completamente aleatoria**. Puede realizarse “con reemplazo”, donde una tupla seleccionada puede ser elegida nuevamente, o “sin reemplazo”, donde cada tupla se selecciona solo una vez.
- **Propósito:**
 - Su objetivo principal es crear una **muestra imparcial** que, si es lo suficientemente grande, debería reflejar las características de la población de manera representativa.
 - Este método ayuda a **proteger el proceso de modelado de sesgos** hacia cualquier característica específica de los datos.
 - En el contexto de la minería de patrones frecuentes, el muestreo puede reducir la posibilidad de perder patrones frecuentes globales al trabajar con un subconjunto de datos más pequeño.

```

1  import pandas as pd
2
3  # Crear un DataFrame de ejemplo
4  data = {'ID': range(1, 101),
5         'Valor': [i*2 for i in range(100)]}
6  df = pd.DataFrame(data)
7
8  # --- Muestreo Aleatorio Simple SIN reemplazo ---
9  # Seleccionar 10 muestras aleatorias. Cada fila solo puede ser elegida una vez.
10 # Usamos random_state para que el resultado sea reproducible.
11 muestra_sin_reemplazo = df.sample(n=10, random_state=42)
12
13 print("--- Muestra Aleatoria Simple (sin reemplazo) ---")
14 print(muestra_sin_reemplazo)
15
16 # --- Muestreo Aleatorio Simple CON reemplazo ---
17 # Seleccionar 10 muestras. Una misma fila podría aparecer varias veces.
18 muestra_con_reemplazo = df.sample(n=10, replace=True, random_state=42)
19
20 print("\n--- Muestra Aleatoria Simple (con reemplazo) ---")
21 print(muestra_con_reemplazo)

```

Muestreo Estratificado *Basado en Han, Pei y Tong (2022); Kuhn y Johnson (2020)*

- **Concepto:** El muestreo estratificado implica **dividir el conjunto de datos o la población en partes mutuamente excluyentes, llamadas estratos**, y luego obtener una muestra de cada uno de estos estratos. Para problemas de clasificación, esto se logra seleccionando muestras al azar dentro de cada clase. Si el resultado es numérico, se pueden construir estratos artificiales basándose en los cuartiles de la distribución de los datos.
- **Propósito:**
 - Asegura una **muestra más representativa**, especialmente cuando los datos están **sesgados** o cuando hay **subgrupos con un número reducido de elementos** que necesitan ser representados. Por ejemplo, en datos de clientes, se podría crear un estrato para cada grupo de edad para garantizar que incluso el grupo más pequeño esté representado.

- Para los modelos de clasificación, esta estrategia garantiza que la **distribución de frecuencia del resultado sea aproximadamente igual** tanto en el conjunto de entrenamiento como en el de prueba. Un ejemplo de aplicación es la predicción del riesgo de accidente cerebrovascular, donde se usa un muestreo estratificado para mantener la proporción de pacientes con y sin accidente cerebrovascular en los conjuntos de entrenamiento y prueba.

```

1 import pandas as pd
2 from sklearn.model_selection import train_test_split
3
4 # Crear un DataFrame de ejemplo con una clase desbalanceada
5 data = {'Caracteristica': range(20),
6         'Clase': ['A', 'A', 'A', 'A', 'A', 'A', 'A', 'A', 'A', 'A', 'B',
7                  'B', 'B', 'B', 'C', 'C', 'C', 'A', 'A', 'B', 'C']}
8 df = pd.DataFrame(data)
9
10 # Variables predictoras (X) y variable objetivo (y)
11 X = df[['Caracteristica']]
12 y = df['Clase']
13
14 # Dividir los datos en entrenamiento y prueba MANTENIENDO la proporción de clases
15 # test_size=0.5 significa que queremos una muestra del 50%
16 # El parámetro 'stratify=y' asegura que la división sea estratificada según las clases
17 # en 'y'
18 X_train, X_test, y_train, y_test = train_test_split(
19     X, y, test_size=0.5, random_state=42, stratify=y
20 )
21
22 print("--- Muestreo Estratificado ---")
23 print("Distribución de clases en el conjunto original:")
24 print(y.value_counts(normalize=True))
25
26 print("\nDistribución de clases en el conjunto de prueba (muestra estratificada):")
27 print(y_test.value_counts(normalize=True))
28 # Observa cómo las proporciones son idénticas en ambos conjuntos.

```

Muestreo por Conglomerados

Basado en Han, Pei y Tong (2022)

- **Concepto:** Si las tuplas del conjunto de datos están agrupadas en M conglomerados mutuamente disjuntos (*clusters*), se obtiene una muestra seleccionando s de esos conglomerados, con $s < M$, y tomando todas las tuplas de los conglomerados elegidos. El agrupamiento no necesita construirse: muchas veces ya viene dado por la organización física o semántica de los datos. El ejemplo canónico es la página de disco: como una base de datos recupera las tuplas de una página por vez, cada página puede considerarse un conglomerado, y aplicar muestreo aleatorio simple sobre las páginas produce una muestra por conglomerados de las tuplas.
- **Propósito:** Es la técnica más eficiente cuando el costo dominante es el **acceso a los datos** y no el cómputo, porque respeta la unidad en que el sistema realmente lee la información. También admite criterios de agrupamiento con semántica propia: en una base de datos espacial, por ejemplo, los conglomerados pueden definirse geográficamente según la cercanía entre áreas.
- **Precaución:** la muestra hereda la homogeneidad interna de los conglomerados. Si las tuplas de un mismo conglomerado se parecen mucho entre sí, la muestra cubre menos variabilidad que una muestra aleatoria simple del mismo tamaño.

```

1 import numpy as np
2 import pandas as pd
3
4 rng = np.random.default_rng(42)
5

```



```

6 # Conjunto de ejemplo con una estructura de conglomerados ya dada:
7 # 20 conglomerados (p. ej. paginas de disco, sucursales, regiones) de 50 tuplas.
8 df = pd.DataFrame({
9     "id": range(1000),
10    "conglomerado": np.repeat(np.arange(20), 50),
11    "valor": rng.normal(size=1000),
12 })
13
14 # Se muestrean CONGLOMERADOS, no tuplas: se eligen 4 de los 20 y se toman enteros.
15 elegidos = rng.choice(df["conglomerado"].unique(), size=4, replace=False)
16 muestra = df[df["conglomerado"].isin(elegidos)]
17
18 print(f"Conglomerados elegidos: {sorted(elegidos.tolist())}")
19 print(f"Tuplas en la muestra: {len(muestra)} de {len(df)}")

```

La ventaja general del muestreo como técnica de reducción de datos es que **el costo de obtener la muestra es proporcional al tamaño de la muestra s , no al tamaño del conjunto N** . La complejidad es potencialmente sublineal respecto del volumen de datos, mientras que otras técnicas de reducción requieren al menos una pasada completa sobre el conjunto.

Muestreo Adaptativo: Aprendizaje Activo

Basado en Han, Pei y Tong (2022)

- **Concepto:** Cuando el muestreo no se decide de antemano sino que se **adapta a lo que el modelo va aprendiendo**, estamos ante las técnicas de **aprendizaje activo** (*active learning*). En este esquema, el algoritmo puede **consultar deliberadamente a un usuario para obtener las etiquetas** de un número selecto de tuplas. La estrategia más común es el **muestreo por incertidumbre** (*uncertainty sampling*), donde el algoritmo elige consultar aquellas tuplas sobre las que tiene **menos certeza de cómo etiquetar**.
- **Propósito:**
 - Es adecuado para situaciones donde los datos son abundantes, pero las **etiquetas de clase son escasas o costosas de obtener manualmente**.
 - Al enfocarse en las tuplas más inciertas, el aprendizaje activo busca **reducir significativamente el número de tuplas que necesitan ser etiquetadas** por humanos en comparación con el aprendizaje supervisado tradicional. Esto simula una intensificación del muestreo en áreas de “incertidumbre” o “alta variabilidad” en los datos.

```

1 import pandas as pd
2 import numpy as np
3 from sklearn.linear_model import LogisticRegression
4 from sklearn.datasets import make_classification
5
6 # Simular un escenario de Aprendizaje Activo (Muestreo por Incertidumbre)
7
8 # 1. Crear un conjunto de datos grande
9 X, y = make_classification(n_samples=1000, n_features=10, n_informative=5, n_redundant
10                             =0, random_state=42)
11 X = pd.DataFrame(X, columns=[f'feature_{i}' for i in range(10)])
12
13 # 2. Simular un pequeño conjunto de datos etiquetado y un gran "pool" sin etiquetar
14 X_labeled, X_unlabeled = X.iloc[:20], X.iloc[20:]
15 y_labeled, y_unlabeled = y[:20], y[20:]
16
17 # 3. Entrenar un modelo inicial con los pocos datos etiquetados
18 model = LogisticRegression()
19 model.fit(X_labeled, y_labeled)
20
21 # 4. Usar el modelo para predecir probabilidades en el pool sin etiquetar

```



```

21 probabilities = model.predict_proba(X_unlabeled)
22
23 # 5. Encontrar el punto de datos con mayor incertidumbre
24 # La incertidumbre es máxima cuando la probabilidad está más cerca de 0.5
25 # Esto equivale a encontrar la fila donde la probabilidad máxima es la más baja
26 uncertainty_scores = 1 - np.max(probabilities, axis=1)
27 most_uncertain_idx = np.argmax(uncertainty_scores)
28
29 # 6. Seleccionar ese punto como el siguiente a ser etiquetado por un humano
30 punto_a_etiquetar = X_unlabeled.iloc[[most_uncertain_idx]]
31
32 print("--- Muestreo Adaptativo (por Incertidumbre) ---")
33 print(f"El modelo tiene la mayor duda sobre el punto con índice (en el pool): {
    most_uncertain_idx}")
34 print("Este es el siguiente punto que se debería etiquetar:")
35 print(punto_a_etiquetar)

```

2. Lectura y procesamiento incremental (chunking): En herramientas como pandas (Python), cuando el dataset no cabe en memoria, podemos leer y procesar los datos en **bloques** o **“chunks”**. Wes McKinney (2022) destaca esta funcionalidad como esencial para manejar archivos grandes. La idea es iterar por partes del dataset sin cargarlo entero a RAM. Por ejemplo, con pandas: `for chunk in pd.read_csv("datos.csv", chunksize=1000000):` ... leerá el archivo CSV en partes de 1 millón de filas. Dentro del bucle, podemos realizar operaciones de EDA sobre cada chunk y acumular resultados parciales. Un caso típico es computar estadísticas agregadas en streaming: supongamos que queremos conocer la distribución de frecuencias de un campo categórico en un dataset enorme. Podemos inicializar un contador e ir actualizándolo con cada bloque:

```

1 import numpy as np
2 import pandas as pd
3
4 # Para que el ejemplo se pueda ejecutar, primero se fabrica el archivo grande.
5 # En un caso real este paso no existe: el CSV ya está en disco.
6 rng = np.random.default_rng(42)
7 pd.DataFrame({
8     "Categoria": rng.choice(["A", "B", "C", "D"], size=500_000, p=[.5, .3, .15, .05]),
9     "Valor": rng.normal(size=500_000),
10 }).to_csv("grandes_datos.csv", index=False)
11
12 # Lo que importa es esto: se recorre el archivo de a bloques y se acumula el
13 # resultado parcial, sin cargarlo entero en memoria.
14 total_counts = pd.Series(dtype=float)
15 for chunk in pd.read_csv("grandes_datos.csv", chunksize=100_000):
16     total_counts = total_counts.add(chunk["Categoria"].value_counts(), fill_value=0)
17
18 print(total_counts.astype(int).sort_index())

```

Al finalizar, `total_counts` contendrá la frecuencia total de cada categoría sin haber cargado todo el dataset simultáneamente. McKinney demuestra esta técnica en su libro, por ejemplo al sumar ocurrencias por bloques en un archivo de 10 mil filas. Esto nos permite explorar distribución de valores, detectar categorías raras o dominantes, etc., en datasets masivos.

Pandas también ofrece parámetros como `nrows` para leer solo las primeras N filas, o `skiprows` para saltar un número de filas – útiles si queremos **inspeccionar una parte** rápidamente. Adicionalmente, al trabajar con archivos delimitados, se puede activar `iterator=True` para obtener un `TextFileReader` (el objeto `chunker`) que nos dé flexibilidad en cómo iterar.

3. Uso de bases de datos y consultas agregadas: Cuando los datos residen en una base de datos SQL o similar, es recomendable **llevar la exploración al lado del servidor** mediante consultas en lugar de traer todos los datos al cliente.

Esto implica aprovechar **operaciones de agregación** (SUM, AVG, COUNT, etc.) y **filtrado en SQL** para resumir datos enormes. Por ejemplo, para un log de millones de registros, una consulta SQL podría computar distribución por tipo en la propia base: `SELECT tipo, COUNT(*) FROM log GROUP BY tipo;`. Los sistemas de gestión de bases de datos están optimizados para manejar grandes volúmenes en disco, usando índices, etc., por lo que delegarles la tarea es eficiente. Una vez obtenidos los resultados agregados (mucho más pequeños), se pueden visualizar fácilmente.

En contextos de *data warehousing*, existen las tecnologías OLAP (Online Analytical Processing) que permiten navegar datos pre-agregados en cubos multidimensionales. Han et al. (2022) señalan que las herramientas OLAP son útiles para **análisis exploratorio en grandes bases de datos**, mediante operaciones como *slice*, *dice*, *drill-down* para ver distintas proyecciones de los datos. Un ejemplo: supongamos un cubo de ventas con dimensiones *tiempo*, *región* y *producto*. Con OLAP, un analista puede rápidamente “rebanar” el cubo para ver ventas de un producto específico en todas las regiones, o “perforar” dentro de una región para ver el desglose mensual, todo ello de forma interactiva y a alta velocidad gracias a pre-cálculos. Este tipo de exploración guiada por cubos resume millones de filas en métricas agregadas (sumas, promedios) que se calculan al vuelo con eficiencia. Así, OLAP provee un EDA de alto nivel, especialmente integrado en tableros empresariales. De hecho, se suele hablar de OLAP-based exploratory data analysis como el puente entre las herramientas de presentación de informes y la minería más profunda de datos.

4. Consideraciones de rendimiento en herramientas tipo pandas: Si usamos entornos como Python, es crucial aprovechar estructuras vectorizadas y bibliotecas optimizadas en C (NumPy, pandas) en lugar de bucles nativos de Python, que serían demasiado lentos con datos extensos. Pandas maneja internamente los datos en **arrays de NumPy** altamente eficientes, lo que permite procesar millones de elementos por segundo en operaciones vectoriales. Sin embargo, hay que escribir el código de modo que use estas operaciones en bloque. Por ejemplo, para calcular estadísticas descriptivas de cada columna, basta un `df.describe()` en pandas que en segundos devuelve media, desviación, cuartiles, etc., incluso en datasets grandes (si caben en memoria). **Polars** es una alternativa **columnar** escrita en **Rust** sobre **Apache Arrow**, con ejecución **multihilo** y dos modos de uso: **eager** (API similar a pandas) y **lazy** con **optimización de consultas** (p. ej., *predicate pushdown* y proyección), lo que la hace muy competitiva para *groupby*, *joins* y agregaciones en millones de filas; además puede **escanear** CSV/Parquet sin cargarlos completos en memoria y ofrece interoperabilidad con pandas/Arrow. También se puede recurrir a **bibliotecas especializadas** para big data: en Python destaca **Dask** (permite analizar datasets mayores que la memoria, distribuidos en particiones) o **PySpark** si se cuenta con un clúster Hadoop/Spark. Estas herramientas extienden las abstracciones de pandas o SQL a entornos distribuidos, pero su uso ya va más allá del EDA tradicional y requiere consideraciones adicionales.

Una táctica simple pero eficaz es **trabajar con tipos de datos eficientes**: asegurarse de usar tipos numéricos de menor precisión cuando sea suficiente (por ejemplo, `int32` en lugar de `int64` si los valores no son tan grandes) y categorizar textos repetitivos (pandas `Categorical`) para ahorrar memoria. Esto permite cargar datasets de mayor tamaño en la RAM disponible. McKinney (2022) discute cómo optimizar tipos al importar datos y cómo evitar copias innecesarias de datos en memoria, lo cual es relevante en EDA de grandes volúmenes.

5. Visualización de grandes datasets (véase la figura sobre sobretrazado y muestreo en el capítulo 1, que se compila como PDF aparte): Un punto crítico es cómo *visualizar* datos muy numerosos. Los gráficos convencionales pueden saturarse o volverse ilegibles si intentamos plotear millones de puntos. Algunas recomendaciones:

- Utilizar **agregaciones visuales**: por ejemplo, en lugar de pintar cada punto en un scatterplot con 10^6 puntos (lo que resultaría en una nube densa negra), podríamos representar la densidad de puntos con colores (heatmap de dispersión) o mediante hexágonos binning (*hexbin plot*). Estas técnicas visuales agrupan puntos cercanos y colorean según frecuencia, mostrando la estructura general sin plotear cada observación individual.
- **Muestreo para visualización**: similar a EDA numérico, a veces conviene graficar solo una muestra aleatoria. Si seleccionamos 10 mil puntos aleatorios de un total de 1 millón, es posible que el patrón global (tendencia, forma de la nube) se perciba casi igual, con la diferencia de que la gráfica será más ligera de renderizar.
- **Herramientas especializadas**: existen librerías diseñadas para big data viz, como Datashader, que rasteriza datos masivos calculando el resultado gráfico en píxeles a partir de los datos agregados. O en R, paquetes como *ggplot2* con *binned plots*. En cualquier caso, el principio es el mismo: evitar intentar dibujar cada elemento individual cuando su cantidad es enorme, y optar por *resúmenes visuales*.

6. Automatización de tareas repetitivas de EDA: En grandes datasets suele haber tareas repetitivas como explorar cada columna, verificar valores faltantes, calcular correlaciones entre decenas de variables, etc. Para eficiencia, se pueden escribir scripts o usar herramientas que generen automáticamente un perfil exploratorio. Por ejemplo, pandas Profiling

(ahora llamado *ydata-profiling*) es una librería que toma un DataFrame y produce un informe HTML con estadísticas y gráficos para cada columna (distribución, valores extremos, correlaciones destacables). En un dataset grande, esto ahorra tiempo al analista, entregando una visión general sin tener que escribir decenas de líneas de código por variable. Sin embargo, debemos ser conscientes de que generar dicho informe sobre un dataset enorme puede llevar tiempo significativo; a veces conviene usarlo sobre una muestra o subconjunto primero.

En resumen, la gestión eficiente del EDA en grandes volúmenes de datos combina **buenas prácticas computacionales** (muestreo, chunking, uso de bases de datos) con **herramientas adecuadas** (OLAP, bibliotecas optimizadas). Como menciona Han et al., aunque las cantidades de datos crezcan, el analista sigue queriendo “*recorrer el conjunto de datos en busca de información interesante*”, y para ello necesita métodos que le permitan *ver el bosque* sin perderse en los millones de árboles. Aplicando estas estrategias, es posible extraer valor exploratorio incluso de *big data* de manera pragmática, obteniendo las ventajas del EDA (descubrimiento de patrones, detección de anomalías, comprensión de distribuciones) sin verse abrumado por la escala.

Visualización narrativa de resultados para modelos de regresión, clasificación y clustering

Basado en Molnar (2025); Hair et al. (2019); Han, Pei y Tong (2022)

Una vez que hemos construido modelos predictivos o descriptivos (como regresiones, clasificadores o segmentaciones por clustering), surge la necesidad de **comunicar sus resultados** de forma efectiva. No basta con presentar métricas numéricas (RMSE, accuracy, etc.); a menudo es más intuitivo y convincente apoyarse en **visualizaciones que cuenten la historia** del modelo: cómo de bien se ajustó, dónde se equivoca, cómo agrupa los datos, etc. En esta sección abordamos técnicas de visualización específicas para tres tipos de modelos comunes –**regresión, clasificación y clustering**– con énfasis en narrar los hallazgos de manera clara para distintos públicos.

Resultados de modelos de Regresión

En un modelo de regresión (sea lineal múltiple, regresión polinomial, etc.), normalmente el objetivo es predecir un valor numérico continuo a partir de ciertas variables explicativas. Más allá de reportar el coeficiente de determinación R^2 o los coeficientes del modelo, es muy ilustrativo usar gráficos para verificar e ilustrar cómo el modelo se desempeña y si cumple supuestos. Algunas visualizaciones clave incluyen:

Gráfico de valores predichos vs. valores reales (scatterplot): es la representación más directa del desempeño punto a punto (fig. 11). En el eje x colocamos el valor real observado (*ground truth*) y en el eje y el valor predicho por el modelo para cada observación. Esta nube permite detectar, de un vistazo, si el modelo reproduce la escala y la forma de la variable objetivo. ¿Qué observar?

1. **Proximidad a la diagonal:** cuanto más cerca estén los puntos de la línea $y = x$ (ideal), menor error absoluto.
 2. **Patrones de dispersión:** un ensanchamiento de la nube a medida que crecen los valores puede sugerir **heterocedasticidad** (el error aumenta con el nivel). Curvaturas o bandas inclinadas pueden indicar **no linealidades** no capturadas.
 3. **Outliers e influencias:** puntos claramente alejados de la diagonal o de la masa principal pueden corresponder a errores de etiquetado, mediciones atípicas o regiones del espacio de covariables mal cubiertas por el entrenamiento.
 4. **Estratificación por conjuntos (Train/Val/Test):** colorear los puntos por *set* permite inspeccionar si el comportamiento es consistente entre particiones; solapamientos similares sugieren estabilidad, mientras que separaciones sistemáticas (p.ej., los puntos de Test se alejan más de la diagonal) alertan sobre **sobreajuste** o **shift** entre distribuciones.
- **Agregar línea de identidad y línea de tendencia:** sobre el mismo scatter conviene trazar la **línea identidad** ($y = x$). Es una guía visual que representa el caso perfecto (predicción igual al valor real). Junto a ella, puede añadirse una **línea de tendencia** (p.ej., un ajuste lineal OLS) para resumir el patrón global de la nube. La comparación entre **pendiente y ordenada al origen** de la tendencia vs. los valores ideales (pendiente ≈ 1 y corte ≈ 0) informa sobre **sesgos sistemáticos**:
 - Pendiente < 1 sugiere **compresión** (el modelo reduce la amplitud: subestima valores altos y sobrestima los bajos).

- Pendiente > 1 sugiere **expansión** (magnifica las diferencias).
 - Corte distinto de 0 indica **sesgo aditivo** (desplazamiento vertical). Además, anotar métricas sintéticas (p.ej., R^2 , MAE, RMSE) dentro del gráfico ayuda a una lectura rápida, pero siempre interpretadas junto a la forma de la nube: un R^2 alto con sesgo evidente en la tendencia exige atención.
- **Jointplot: scatter + distribuciones marginales (KDE)**: la figura presentada es un **jointplot** de Seaborn que integra en un solo lienzo el **scatter central** con la línea identidad (y la posibilidad de incluir la tendencia) y, en los márgenes superior (para x = reales) y derecho (para y = predichos), las **distribuciones de densidad (KDE)**. Esta combinación aporta dos lecturas adicionales clave:
 1. **Calibración marginal**: comparar las KDE de reales vs. predichos permite ver si el modelo reproduce la **forma univariada** de la variable objetivo (rango, asimetría, modas). Diferencias notorias —por ejemplo, predichos con menor varianza o colas recortadas— revelan **sub/ sobre-dispersión** o pérdida de colas.
 2. **Consistencia entre conjuntos**: al colorear Train/Val/Test tanto en el scatter como en las KDE marginales, se chequea si las particiones comparten rango y forma. Un buen solapamiento sugiere **desempeño estable**; discrepancias (p.ej., curva de Test desplazada) apuntan a **cambio de distribución** o a que el modelo generaliza peor fuera del entrenamiento. En la figura también se incluye un recuadro con R^2 (global y de Test) que resume el ajuste. Leído junto a la diagonal y a las KDE, brinda una visión completa: **precisión punto a punto** (cercanía a $y = x$), **sesgo global** (tendencia), y **calibración** (comparación de densidades).




Figura 11: Predicho contra real, con distribuciones marginales. Una red predice el índice de Tanimoto entre pares de compuestos de la vía metabólica de la glucólisis, a partir de representaciones obtenidas del grafo de reacciones en lugar de la estructura molecular. Cada punto es uno de los 1081 pares que surgen de combinar de a dos los 47 compuestos de estructura conocida, coloreado según el conjunto al que pertenece. **Qué mirar:** la nube se apoya sobre la diagonal, que es el ideal sin error, pero hay una decena de puntos naranjas —de prueba— muy lejos de ella: son pares cuya similitud el modelo estima mal, y no se verían en una tabla de métricas. Las curvas de los márgenes resumen la distribución de los valores reales (arriba) y los predichos (derecha); que coincidan en forma y rango sugiere que el modelo no está comprimiendo ni desplazando la escala. El recuadro reporta el R^2 de prueba y el del conjunto completo: **0,92 contra 0,98**, y esa diferencia es informativa, porque el ajuste sobre datos no vistos siempre es peor que el global. (Borzone, Di Persia y Gerard, 2022)

Intervalos de confianza/predicción en la curva: Si es una regresión simple o polinomial, a veces se dibuja la recta (o curva) ajustada sobre el scatterplot de los datos originales, acompañada de bandas de confianza. Esto es útil para narrar cuánto del patrón original captura el modelo. Por ejemplo, podríamos mostrar: “la línea de regresión (en azul)

sigue la tendencia ascendente; las bandas sombreadas indican el 95% de intervalo de confianza de la predicción, aún relativamente estrechas, lo que da cierta confianza en el pronóstico dentro del rango observado”. Este tipo de visual es típico en análisis bivariados para mostrar el *fit*. Herramientas como Seaborn en Python generan fácilmente *regplot* con estas bandas.

Importancia de variables y efectos: Aunque estrictamente esto entra en feature engineering, es relevante para la comunicación: para modelos como regresiones con muchas variables, a veces se presentan gráficos de barras con la magnitud de los coeficientes estandarizados, indicando cuáles son los predictores más importantes. También las **gráficas de efectos parciales** (Partial Dependence Plots) ayudan a narrar cómo una variable influye en la respuesta predicha, manteniendo las otras constantes. Por ejemplo, un PDP podría mostrar: “A medida que X aumenta, la predicción de ventas sube no linealmente hasta saturarse”. Estas visualizaciones son valiosas para traducir el modelo a insights accionables, explicando la relación descubierta.

Gráficos de influencia y outliers (definiciones, interpretación y alternativas modernas)

Definiciones clave

- **Residuo estandarizado:** diferencia entre el valor observado y el valor predicho para una observación, escalada por una estimación de su desvío estándar. Permite comparar residuos entre casos en una misma escala.
- **Apalancamiento (*leverage*, h_i):** cuantifica cuánto “tira” una observación sobre el ajuste del modelo. Equivale a la diagonal de la **matriz sombrero** en regresión lineal y refleja cuán extremo es el punto en el espacio de predictores. Reglas prácticas: valores por encima de $2p/n$ o $3p/n$ (con p parámetros y n observaciones) merecen atención.
- **Distancia de Cook (D_i):** medida compuesta que integra **residuo** y **apalancamiento** para estimar cuánto cambiarían simultáneamente los **coeficientes** y los **valores ajustados** si se eliminara la observación i . En los gráficos diagnósticos, suele representarse con **isocurvas** (líneas rojas punteadas); puntos fuera de estas curvas se consideran **influyentes**.

Gráfico de residuos vs. apalancamiento (residuals vs. leverage) La fig. 12 muestra el caso típico: una observación que queda fuera de las isocurvas de Cook y que, por lo tanto, conviene revisar antes de darla por buena.




Figura 12: Doce estudiantes, y uno que estudió el doble que el resto y aun así rindió por debajo de lo esperado. Esa observación queda a la derecha (apalancamiento $h = 0,75$: tira con fuerza del ajuste) y abajo (residuo estandarizado cercano a -3), y sobre todo **fuera de la isocurva de Cook igual a 1**. Las once restantes se apiñan en la franja de apalancamiento bajo. Es la lectura que importa: un punto puede ser influyente sin ser el residuo más grande, y por eso conviene mirar las dos coordenadas juntas en lugar de los residuos por separado.

- **Eje x:** apalancamiento (h_i).
- **Eje y:** residuo estandarizado (r_i).
- **Curvas:** isocurvas de **Distancia de Cook**.
- **Lectura:**

- Puntos **fuera** de las curvas de Cook = **observaciones influyentes**.
- Puntos con $|r_i|$ **alto** y h_i **bajo** = *outliers* en la respuesta que **no** cambian mucho los coeficientes.
- Puntos con h_i **alto** y $|r_i|$ **moderado** = casos estructuralmente extremos que **condicionan** el ajuste.
- Umbrales prácticos: $|r_i| > 2$ (o > 3 , más conservador) y $h_i > 2p/n$ o $3p/n$.

Cómo actuar ante puntos influyentes

1. **Verificar calidad de datos:** descartar error de carga, medición o situaciones irrelevantes al objetivo del modelo.
2. **Re-especificar el modelo:** considerar transformaciones, términos no lineales o de interacción, regresión polinómica, GLMs (con residuos de deviance/Pearson y apalancamiento ponderado), GAMs o enfoques **robustos**.
3. **Análisis de sensibilidad:** *leave-one-out* (o aproximado) para cuantificar cuánto cambian coeficientes y métricas al excluir el/los puntos.
4. **Decidir y documentar:** si corresponde, reportar resultados **con y sin** las observaciones influyentes, explicitando el criterio.

Ejemplo de reporte: “El gráfico de residuos vs. apalancamiento identificó 2 casos cercanos a las isocurvas de Distancia de Cook y 1 fuera de ellas. Tras verificar datos, re-especificamos el modelo con un término cuadrático y mejoró la adecuación (menor $|r_i|$ y reducción de D_i). Reportamos ambos ajustes por transparencia.”

Alternativas prácticas en *deep learning* para detectar observaciones influyentes Cuando el objetivo es **detectar puntos influyentes** (el rol que cumple residual vs. leverage en OLS), en redes profundas funcionan mejor diagnósticos específicos del entrenamiento y de las representaciones:

- **Funciones de influencia:** aproximan cuánto cambiaría la **pérdida** o la **predicción** sobre un punto objetivo si se retirara o se reponderara un punto de entrenamiento. Devuelven un **ranking** de ejemplos influyentes sin necesidad de reentrenar el modelo completo. Molnar (2025) las presenta como la extensión natural del diagnóstico clásico de influencia a modelos donde la matriz sombrero no existe: la pregunta sigue siendo la misma —qué observaciones sostienen el resultado— pero la respuesta ya no puede leerse de una fórmula cerrada.
- **Leave-One-Out aproximado:** mide la variación de predicciones o parámetros al **excluir** un punto, usando atajos numéricos (por ejemplo, aproximaciones de Hessiano/NTK o *warm-starts*).
- **Calibración y *binned residuals* (clasificación):** inspección por *bins* de probabilidad con **residuos de deviance/Pearson**, **curvas de calibración**, **ECE** y **reliability diagrams** para detectar zonas donde el modelo se **descalibra** (frecuentemente asociadas a ejemplos problemáticos).
- **Detección de *outliers*/OOD en embeddings:** análisis en el espacio latente (p. ej., distancia de **Mahalanobis** o densidad local) para ubicar ejemplos **atípicos** o fuera de distribución que ejercen “**alta palanca geométrica**”, aun sin una noción clásica de leverage.

Heurística útil en MLPs de regresión: congelar el feature extractor y tratar la **última capa lineal** como una regresión (con o sin ridge) para calcular un **apalancamiento aproximado** y un **análogo de Distancia de Cook**; no es exacto, pero orienta la auditoría de casos.

En definitiva, en regresión la visualización narrativa busca **confirmar y explicar el ajuste del modelo**. Podemos validar su calidad mostrando predichos vs. observados, y **explicar su significado práctico** destacando patrones (como “el modelo se queda corto en altas temperaturas”) y enfatizando qué predictores importan. Esto convierte números fríos (R^2 , coeficientes) en historias comprensibles (ej.: “la relación entre publicidad y ventas es fuerte hasta cierto punto, luego se estabiliza según nuestro modelo, como vemos en esta curva...” etc.).

Resultados de modelos de Clasificación

Para modelos de clasificación (sean árboles de decisión, random forest, redes neuronales o una regresión logística), las visualizaciones se enfocan tanto en el rendimiento global del clasificador como en la naturaleza de sus errores y a veces en la lógica de decisión. Algunas de las representaciones más utilizadas son:

Matriz de confusión: Basado en Han, Pei y Tong (2022); Kuhn y Johnson (2020)

La **matriz de confusión** (fig. 13) es una **herramienta fundamental para analizar el rendimiento de un modelo de clasificación**, especialmente útil para entender qué tan bien el clasificador reconoce tuplas de diferentes clases. Se presenta

como una **tabla de tabulación cruzada de las clases observadas (reales) y las clases predichas**. Para un problema con m clases, la matriz es de al menos m por m . Las **filas corresponden a la clase real (Actual)** y las **columnas a la clase predicha (Pred)**, y cada entrada $CM_{i,j}$ en la fila i y columna j indica el número de tuplas de la clase real i que fueron clasificadas por el modelo como clase j . Las **predicciones correctas se sitúan en la diagonal principal** de la matriz ($CM_{1,1}$ a $CM_{m,m}$), mientras que las **predicciones erróneas o “confusiones” se encuentran fuera de esta diagonal**.




Figura 13: Matriz de confusión para un modelo de clasificación con 3 clases (A, B, C). Las filas representan las clases reales y las columnas las predichas; Los números indican la cantidad de casos en cada categoría; la diagonal principal muestra los aciertos y las celdas fuera de la diagonal, los errores. Se observa, por ejemplo, que el modelo **clasificó correctamente 43 casos de la clase A** (celda Actual A / Pred A), **confundió 5 casos de A como C**, etc.

Para problemas de **clasificación binaria** (dos clases), se utilizan términos específicos para interpretar las entradas:

- **Verdaderos Positivos (TP):** Tuplas positivas que fueron correctamente etiquetadas como positivas.
- **Verdaderos Negativos (TN):** Tuplas negativas que fueron correctamente etiquetadas como negativas.
- **Falsos Positivos (FP):** Tuplas negativas que fueron incorrectamente etiquetadas como positivas (error de Tipo I).
- **Falsos Negativos (FN):** Tuplas positivas que fueron incorrectamente etiquetadas como negativas (error de Tipo II).

A partir de la matriz de confusión, se derivan diversas **medidas y métricas** para una evaluación más detallada del modelo:

- **Precisión (Accuracy):** Porcentaje de tuplas clasificadas correctamente por el modelo. Se calcula como $(TP + TN) / (P + N)$, donde P es el total de tuplas positivas y N el total de tuplas negativas. La precisión puede ser engañosa si existe **desequilibrio de clases**.
- **Sensibilidad (Recall o Tasa de Verdaderos Positivos):** Proporción de tuplas positivas reales que fueron correctamente identificadas por el clasificador; es crucial cuando la clase de interés es rara.
- **Especificidad:** Proporción de tuplas negativas reales que fueron correctamente identificadas por el clasificador.
- **Precisión (Precision):** Proporción de tuplas etiquetadas como positivas que son realmente positivas.
- **Medida F (F-score o F1-score):** Media armónica de la precisión y la sensibilidad, útil para equilibrar ambas métricas, especialmente en problemas con clases desequilibradas.

Curvas ROC y métricas asociadas La fig. 14 muestra la lectura habitual de una curva ROC.:

Basado en Han, Pei y Tong (2022); Kuhn y Johnson (2020)

La **Curva ROC (Receiver Operating Characteristic)** es una herramienta gráfica clave para evaluar clasificadores, especialmente en **problemas binarios**. Su objetivo es mostrar el **trade-off** entre la **sensibilidad** o **TPR** (tasa de verdaderos positivos) y la **FPR** (tasa de falsos positivos) a medida que varía el **umbral de decisión**. En el gráfico, el **eje vertical** representa la **TPR** y el **eje horizontal** la **FPR** (equivalente a $1 - \text{especificidad}$). Para **trazar** la ROC, el clasificador debe devolver **probabilidades** (o puntajes) por instancia: ordenamos de mayor a menor score y vamos moviendo el umbral; cuando encontramos un **VP** la curva avanza **hacia arriba** (aumenta TPR) y cuando encontramos un **FP** avanza **a la derecha** (au-

menta FPR). La **curva ideal** se aproxima al **rincón superior izquierdo** (alta TPR con baja FPR). La **diagonal** del gráfico representa el **azar**; cuanto más cerca esté la ROC de esa diagonal, **menor capacidad discriminativa** tiene el modelo. El **Área Bajo la Curva (AUC)** resume el rendimiento global: $AUC = 1.0$ indica separación perfecta y valores cercanos a 0.5 indican falta de poder predictivo. El AUC suele ser **menos sensible al desbalance de clases** que la precisión simple. Modelos que entregan probabilidades (p. ej., **regresión logística**, **Naive Bayes**) son adecuados para construir ROC. Para **multiclase**, se puede extender vía **one-vs-rest** y promediar (macro/micro) las curvas y AUC.




Figura 14: Curva ROC del modelo. La línea azul muestra la relación TPR–FPR a distintos umbrales; el área bajo la curva ($AUC \approx 0.90$) refleja buen poder discriminativo. La línea punteada diagonal indica el desempeño al azar ($AUC = 0.50$). El marcador señala un punto de corte donde se logra $TPR \approx 85\%$ con $FPR \approx 10\%$, un equilibrio razonable para esta aplicación.

Cómo leer la figura. La curva **se acerca al rincón superior izquierdo** y el $AUC \approx 0.90$ sugiere **muy buen poder discriminativo**. El punto marcado ($FPR \approx 0.10$, $TPR \approx 0.85$) ilustra un **umbral operativo** que logra simultáneamente **altas detecciones** y **bajos falsos positivos**; esta narrativa ayuda a **elegir el umbral en producción** según priorices reducir falsos positivos o maximizar detecciones. Si trabajás con **multiclase**, repetís el procedimiento **uno-contra-todos** por clase y reportás el **AUC macro/micro** para una visión agregada.

Curva Precision-Recall La fig. 15 ilustra el compromiso entre precisión y exhaustividad.:

Basado en Han, Pei y Tong (2022); Kuhn y Johnson (2020)

La **Curva de Precisión–Recall (PR)** es una visualización clave para evaluar clasificadores, especialmente desde la perspectiva de **recuperación de información** y cuando hay **desequilibrio de clases**. Al igual que la ROC, se construye recorriendo **todos los umbrales de probabilidad** que el modelo puede producir para la clase positiva y graficando dos estadísticas: la **Precisión** (proporción de predicciones positivas que son realmente positivas, $TP/(TP + FP)$) y la **Exhaustividad/Recall** (proporción de positivos reales correctamente identificados, $TP/(TP + FN)$). La precisión refleja la **exactitud** de las predicciones positivas; el recall, la **cobertura** de los casos positivos. Existe una **tensión natural** entre ambas: aumentar el recall suele reducir la precisión. Un modelo ideal traza una PR que se acerca al **ángulo superior derecho**. Para resumir el rendimiento puede usarse el **Área Bajo la Curva PR (AUC-PR)**: valores altos indican buen poder discriminativo, mientras que una curva próxima a una **línea horizontal a nivel de la prevalencia** sugiere poca capacidad predictiva. Cuando las clases están desbalanceadas, **precisión y recall** (y métricas derivadas) son **más informativas que la accuracy**. La **Medida F** ($F_1 = 2 \frac{Prec \cdot Rec}{Prec + Rec}$) combina ambas en un único valor; su generalización F_β permite ponderar más la precisión o el recall según la aplicación.

Cómo leer la figura. Si el objetivo es “no perder positivos” (alto recall), la curva indica **cuánta precisión estamos dispuestos a sacrificar**: “Aunque el modelo alcanza 90% de recall, la precisión cae a ~50%, implicando muchas alertas falsas. En cambio, al 70% de recall la precisión es ~80%, un balance más conservador.” Esta narrativa facilita **acordar el umbral** con los requisitos del negocio o del dominio.




Figura 15: Curva Precisión-Exhaustividad (PR). La curva muestra cómo, al exigir mayor recall, suele caer la precisión. Se destacan dos puntos operativos: con recall $\approx 90\%$ la precisión $\approx 50\%$ (muchos falsos positivos); con recall $\approx 70\%$ la precisión $\approx 80\%$ (equilibrio más conservador). Esta lectura ayuda a elegir el umbral en producción según el costo de los falsos positivos vs. falsos negativos.

Visualización de la lógica del modelo: En modelos interpretables como los árboles de decisión, se puede incluir el diagrama del árbol con nodos y ramas. Esto permite contar la “historia” de cómo el modelo decide. Por ejemplo: “El árbol de decisión aprendido primero segmenta por la variable ‘Edad > 45 años’; si es sí, entonces... etc. Vemos que la primera división ya separa significativamente las clases (nodo color verde vs rojo).” Sin embargo, árboles grandes son difíciles de seguir para la audiencia general; a veces se prefiere resumirlos: **reglas de decisión** extraídas (p.ej., “Si Ingresos > \$50K y Propietario=True, entonces clase = ‘A’”).

Gráfico de importancia de variables (Regresión y Clasificación):

Basado en Molnar (2025); Kuhn y Johnson (2020); Han, Pei y Tong (2022)

El **gráfico de importancia de variables** es una visualización clave para **entender la contribución relativa de cada predictor** en las predicciones de un modelo. Ayuda a **identificar cuáles variables influyen más en el resultado**, facilitando decisiones de **selección de características**, **simplificación del modelo** y **mejora de interpretabilidad** cuando hay muchos predictores.

Cómo se calcula (enfoque de permutación, modelo-agnóstico) La forma más usada y comparable entre modelos consiste en **destruir artificialmente** la información de una variable y **medir cuánto empeora** el rendimiento:

1. Entrená el modelo y calculá un puntaje base L_0 (por ejemplo, error, log-loss, AUC negativo, etc.).
2. Para cada predictor X_j : **permutá** sus valores en el set de evaluación (o usá otra perturbación equivalente).
3. Volvé a predecir y calculá L_j^* .
4. La **importancia** de X_j se cuantifica como $VIP_j^{\text{diff}} = L_j^* - L_0$ (o bien el **ratio** L_j^*/L_0).
5. **Repetí** la permutación varias veces y **promediá** (reportá desvíos/intervalos) para reflejar la **incertidumbre** del procedimiento.

Intuición: si al permutar X_j el desempeño **empeora mucho**, entonces X_j era **importante**; si casi no cambia, su aporte al modelo es menor.

Este método es **modelo-agnóstico**: sirve para **cualquier** clasificador o regresor y permite **comparar variables entre modelos** con estructuras distintas. Nace como generalización de la importancia **out-of-bag** en los **bosques aleatorios** y hoy es una práctica estándar, desarrollada en detalle por Molnar (2025).

Alternativas modelo-específicas (cuándo tiene sentido)

- **Lineales/regulares:** magnitud de **coeficientes normalizados** o **p-values**.
- **Árboles/ensembles:** uso/acumulación de **ganancias de impureza** o métricas OOB/AUC por variable; hay implementaciones específicas (p. ej., en Random Forest o Gradient Boosting).




Figura 16: Medidas de importancia de variables basadas en una única permutación para las variables explicativas incluidas en el modelo de bosque aleatorio (random forest) para los datos del Titanic, utilizando 1-AUC como función de pérdida.

Cómo leer el gráfico La fig. 16 es un ejemplo de gráfico de importancia por permutación.

Suele mostrarse como **barras horizontales ordenadas** de mayor a menor importancia; es buena práctica incluir **errores estándar/boxplots** sobre la puntuación (por remuestreo/permutaciones repetidas).

- **Valores grandes** = mayor caída de desempeño al destruir la variable = **más importante**.
- **Atención a la correlación:** variables fuertemente correlacionadas pueden **“repartirse”** la importancia; considerará **permutar en grupo** o complementar con análisis de dependencia parcial/SHAP.
- **Evitar leakage:** calcula la importancia en un **conjunto de validación** correcto (o vía OOB) y respetá el **pipeline** de preprocesamiento.

¿Para qué sirve?

- **Simplificación:** quitar variables irrelevantes reduce complejidad y mejora robustez.
- **Exploración:** comparar rankings entre modelos revela **interrelaciones** y guía **análisis posteriores**.
- **Validación con conocimiento de dominio:** los **top-predictores** deben ser plausibles; discrepancias ayudan a **auditar** el modelo.
- **Generación de conocimiento:** variables destacadas pueden sugerir **nuevos factores** a investigar.

Resultados de modelos de Clustering (segmentación)

En técnicas de clustering o segmentación (como *k-means*, clustering jerárquico, DBSCAN, entre otros), el fin es descubrir grupos naturales en los datos no etiquetados. La narrativa visual aquí se orienta a **describir esos grupos** de manera comprensible: tanto su separación entre sí como sus características internas. Algunas herramientas visuales útiles son:

Dispersogramas con clusters: Si los datos son bidimensionales (2 variables) o podemos reducirlos a 2 dimensiones principales (p. ej. usando PCA), un gráfico de dispersión etiquetando cada punto según el cluster asignado (con distinto color o forma) es muy ilustrativo (fig. 17). Permite ver cómo quedaron formados los conglomerados en el espacio. Por ejemplo, en la figura se muestra una dispersión de datos simulados con 3 clusters descubiertos por *k-means*. Cada color representa un cluster y los centroides se marcan con un símbolo especial:

Este tipo de gráfico permite contar la “historia” de segmentación: “Como podemos ver, el algoritmo identificó 3 grupos bien separados en las variables características 1 y 2. El Cluster 1 (rojo) corresponde a puntos con valores bajos en ambas características, el Cluster 2 (verde) agrupa puntos con valores altos en ambas, y el Cluster 3 (azul) representa un grupo mixto con valores altos en la segunda característica pero bajos en la primera. La distancia entre centroides indica que especialmente el cluster verde está bastante alejado de los otros dos, implicando que sus miembros son muy distintos.” Esto ya da una intuición de cómo difieren los grupos. Hay que tener cuidado: esta visualización funciona genial en 2D, pero si los datos originales son de mayor dimensión, es una proyección; por ello es común usar PCA para reducir a 2 componentes principales que retengan la mayor variación, o técnicas tipo t-SNE/UMAP para representaciones 2D (aunque estas últimas no preservan escalas, son más para ver forma). En cualquier caso, la narrativa se centra en “*vemos agrupamientos distintos*”.




Figura 17: Visualización de clusters en un espacio bidimensional. Cada punto corresponde a una observación, coloreada según el cluster asignado por k-means (Cluster 1 en rojo, Cluster 2 en verde, Cluster 3 en azul). Las 'X' negras señalan los centroides. Se aprecian agrupamientos diferenciados: el Cluster 1 (rojo) se concentra cerca del origen (0,0); el Cluster 2 (verde) alrededor de (5,5); y el Cluster 3 (azul) cerca de (0,5).

Gráfico de perfiles (radar o paralelo): Más allá de la separación geométrica, interesa caracterizar cada cluster en términos de las variables originales (fig. 18). Una manera es tomar las *medias* (o medianas) de cada variable dentro de cada cluster y compararlas. Por ejemplo, si tenemos 5 variables descriptivas de clientes y 4 segmentos resultantes, podríamos hacer un **gráfico de radar** (polígono por segmento) o un **gráfico de barras agrupadas** comparando las medias. Así se narraría: “El segmento 1 (azul) se caracteriza por tener alta satisfacción (8.7/10) pero bajo gasto promedio (\$100), mientras que el segmento 3 (verde) tiene la inversa: baja satisfacción (5.2) pero alto gasto (\$500). El segmento 2 (rojo) es joven (edad media 25) y tecnológico (alto uso de app), a diferencia del segmento 4 (naranja) de mayor edad (edad media 60) y preferencia por canal presencial.” Este relato apoyado en la visualización de perfiles da vida a los clusters más allá de un número o color – los convierte en “personajes” con comportamientos distinguibles. Hair et al. (2019) enfatizan la importancia de describir los clusters en términos comprensibles para las partes interesadas, lo que suele lograrse mediante tales descripciones de variables promedio por grupo (una tabla o gráfico de perfil).




Figura 18: Perfiles de clusters por medias normalizadas (radar). Segmento 1 (azul): alta satisfacción y bajo gasto; Segmento 3 (verde): baja satisfacción y alto gasto; Segmento 2 (rojo): joven con alto uso de app; Segmento 4 (naranja): mayor edad y fuerte preferencia por canal presencial. Cada eje corresponde a una variable (escalas normalizadas a [0,1] para comparabilidad).

Dendrograma (para clustering jerárquico): Si se usó un método jerárquico, un **dendrograma** es la visualización natural. Muestra en un árbol las fusiones de clusters en cada nivel de distancia. Puede ser un poco abrumador con muchos elementos, pero es útil para decidir el número de clusters (corte del dendrograma) y para ver qué elementos se agrupan primero. Narrativamente: “El dendrograma de la fig. 19 indica que hay esencialmente dos grandes ramas (los datos se dividen en 2 grupos principales a una distancia ≈ 5). Si cortamos el árbol a ese nivel, tendríamos 2 clusters; sin embargo, observando la siguiente rama, vemos que uno de esos clusters principales se subdivide en 2 subgrupos bien separados a

distancia ≈ 3 , sugiriendo que un corte en 3 clusters es más adecuado para captar la estructura. Los clientes 5 y 12 resultan muy similares entre sí (se unieron temprano), mientras que el cliente 7 queda solo hasta el final, revelando que podría ser un caso aislado (outlier).” Esta explicación ayuda a justificar por qué se eligió cierto número de clusters y qué puntos son atípicos por no integrarse en ninguno hasta distancias grandes.




Figura 19: Dendrograma de clustering jerárquico (método Ward). Las líneas punteadas muestran cortes ejemplares: a distancia ≈ 5 se obtienen 2 grupos principales; a distancia ≈ 3 , el grupo derecho se subdivide en dos subgrupos bien separados, sugiriendo 3 clusters. Se observa que “Cliente 5” y “Cliente 12” se unen muy temprano (alta similitud), mientras que “Cliente 7” permanece aislado hasta el final, indicando un posible outlier.

Otras visualizaciones especializadas: En segmentos de clientes a veces se usan mapas u otras representaciones. Por ejemplo, un *heatmap* de correlaciones entre clusters y variables categóricas (para ver si un cluster tiene mayor proporción de hombres, por decir). Estas visualizaciones ya son más específicas, pero todas buscan **dar significado a los clusters**.

En la comunicación de clustering, a menudo se le da un **nombre o etiqueta a cada cluster** basado en su perfil principal, para facilitar la narrativa. Por ejemplo: “Cluster 1: *Usuarios novatos de bajo consumo*, Cluster 2: *Usuarios experimentados premium*, Cluster 3: *Clientes tradicionales infrecuentes*”. Estas etiquetas, acompañadas de visualizaciones como las descritas, cuentan una historia completa: hemos segmentado la población y aquí están los “personajes” resultantes con sus rasgos.

También es importante comunicar **la utilidad**: quizás mostrar que ciertos clusters tienen valor monetario muy dispar (“el cluster 2 gasta 5 veces más que el 1, como se ve en la comparación de gasto promedio”), lo cual justifica focalizar estrategias comerciales diferentes.

Finalmente, se puede incluir algún indicio de la **calidad del clustering**: por ejemplo, mencionar el índice de Silueta promedio para decir qué tan separados están (quizá con un gráfico de siluetas por cluster), o simplemente comentar “los grupos están bien diferenciados como se observó en el scatter plot, salvo algo de traslape entre 1 y 3, lo que indica que podríamos considerar subdividirlos o revisar variables adicionales”.

En resumen, la visualización narrativa en clustering convierte resultados abstractos (asignaciones a clusters) en **historias concretas sobre grupos** en los datos: cómo se distribuyen (gráfico espacial), cuáles son sus características distintivas (gráfico de perfil), cómo se relacionan entre sí (dendrograma o distancias), y qué implicaciones tienen.

Bibliografía

- Borzone, E., Di Persia, L.E. y Gerard, M. (2022). *Neural model-based similarity prediction for compounds with unknown structures*. Applied Informatics, 5th International Conference (ICAI 2022). sinc(i), FICH-UNL/CONICET.
- Hair, J.F., Black, W.C., Babin, B.J. & Anderson, R.E. (2019). *Multivariate Data Analysis*. 8va edición. Cengage.
- Han, J., Pei, J. & Tong, H. (2022). *Data Mining: Concepts and Techniques*. 4ta edición. Morgan Kaufmann.
- Kuhn, M. & Johnson, K. (2020). *Feature Engineering and Selection: A Practical Approach for Predictive Models*. CRC Press.

McKinney, W. (2022). *Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter*. 3ra edición. O'Reilly Media.

Molnar, C. (2025). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. 3ra edición.

Nussbaumer Knaflic, C. (2015). *Storytelling with Data: A Data Visualization Guide for Business Professionals*. Wiley.